

Relatório de Análise de Dados

Discentes: Marlon Neves, Eduardo Rodrigues, Otávio Queiroz

Urutaí – GO, 2025

1. Introdução

Este relatório apresenta a metodologia e os resultados do trabalho desenvolvido pelo grupo na competição de análise de dados proposta em sala. O objetivo foi melhorar os resultados do artigo de referência de Artur Duarte Monteiro, Guilherme Pereira da Silva e Nattane Luiza da Costa, que aplicou Recursive Feature Elimination (RFE) com Random Forest para prever inadimplência em cartão de crédito.

A base utilizada é a Default of Credit Card Clients (UCI Machine Learning Repository), com 30.000 registros de clientes de Taiwan coletados em 2005, contendo 23 variáveis explicativas e uma variável-alvo binária indicando inadimplência no mês seguinte.

O grupo implementou três melhorias em relação ao artigo base: criação de novas variáveis (Feature Engineering), balanceamento de classes com SMOTE e aumento do número de árvores do Random Forest. O código foi desenvolvido inteiramente em R, com o pacote caret.

2. Metodologia

2.1. Pré-processamento

Os dados foram carregados diretamente do repositório UCI via download automático. As etapas de pré-processamento seguiram o artigo base:

- Remoção da coluna ID e renomeação da variável-alvo para "default";
- Agrupamento de categorias não documentadas em EDUCATION (valores 0, 4, 5, 6) e MARRIAGE (valor 0) na categoria "Outros";
- Remoção de valores infinitos (Inf) gerados nas divisões da engenharia de atributos, seguida de remoção de linhas com NA;
- Conversão de variáveis categóricas para fator e da variável-alvo para fator com rótulos "Pagador" e "Devedor";

- Particionamento estratificado 80% treino / 20% teste, preservando a proporção de devedores.

2.2. Melhoria 1 – Feature Engineering

Foram criadas três novas variáveis com maior poder preditivo:

- SOMA_ATRASOS: soma do status de pagamento dos seis meses (PAY_0 a PAY_6), indicando atraso crônico;
- USO_LIMITE_ATUAL: razão entre BILL_AMT1 e LIMIT_BAL, capturando o percentual de utilização do crédito;
- RAZAO_PAGAMENTO_ATUAL: razão entre PAY_AMT1 e BILL_AMT1, indicando quanto da fatura foi de fato quitado.

2.3. Seleção de Variáveis – RFE

O RFE foi configurado com Random Forest como avaliador externo (rfFuncs customizado com twoClassSummary), validação cruzada de 5 dobras e subconjuntos de tamanho {5, 10, 15, 20, 25}, otimizando a métrica AUC/ROC. O algoritmo convergiu para 19 variáveis como subconjunto ótimo.

2.4. Melhoria 2 – SMOTE e ntree = 500

Para combater o desbalanceamento (~22% de devedores), aplicou-se SMOTE durante o treinamento via parâmetro `sampling = "smote"` no `trainControl`. Adicionalmente, o número de árvores foi aumentado de 100 (artigo base) para 500, reduzindo a variância do modelo final.

2.5. Melhoria 3 – Otimização de Limiar (Threshold Tuning)

O ponto de corte de classificação foi calibrado pelo índice de Youden (equivalente ao KS), utilizando `coords()` do pacote `pROC`. O limiar ótimo identificado foi 0,38. Foram avaliados três cenários: padrão (0,50), ótimo por KS (0,38) e agressivo (0,30), permitindo adaptar o modelo ao apetite de risco da instituição.

3. Resultados

3.1. Variáveis Seleccionadas

O RFE identificou 19 variáveis como subconjunto ótimo. A Tabela 1 lista as cinco de maior importância (critério Gini). As variáveis de status de pagamento mais recentes (PAY_0 e PAY_2) lideraram o ranking, confirmando que o histórico recente de pagamentos concentra o principal sinal preditivo.

Tabela 1 – Top 5 variáveis seleccionadas pelo RFE (importância Gini).

Ranking	Variável	Descrição
1º	PAY_0	Status de Pagamento de Setembro
2º	PAY_2	Status de Pagamento de Agosto
3º	BILL_AMT1	Valor da Fatura de Setembro
4º	PAY_AMT1	Valor Efetivamente Pago em Setembro
5º	LIMIT_BAL	Limite de Crédito Total Concedido

Fonte: elaboração própria a partir da execução do script R.

3.2. Melhorias Implementadas

A Tabela 2 resume as quatro melhorias aplicadas em relação ao artigo base.

Tabela 2 – Melhorias implementadas em relação ao artigo base.

Melhoria	Descrição
Feature Engineering	Criação de 3 novas variáveis: SOMA_ATRASOS, USO_LIMITE_ATUAL e RAZAO_PAGAMENTO_ATUAL
SMOTE	Balanceamento da classe minoritária (devedores ~22%) durante o treinamento
ntree = 500	Aumento de 100 para 500 árvores, reduzindo variância do modelo
Threshold Tuning	Otimização do limiar via índice de Youden/KS; limiar ótimo: 0,38

Fonte: elaboração própria.

3.3. Desempenho – Comparação de Métricas

O modelo final atingiu AUC de 0,753, competitiva com o benchmark da literatura. A Tabela 3 compara todos os cenários avaliados. Com o limiar padrão (0,50), o modelo manteve acurácia de 81,78%, idêntica ao artigo base. Com o limiar 0,38 (Youden/KS), a sensibilidade subiu +7,68 p.p. — de 37,53% para 45,21% — mantendo a especificidade acima de 90%.

Tabela 3 – Comparação de métricas entre os cenários avaliados.

Cenário	Acurácia	Sensibilidade	Especificidade	AUC
Benchmark – Yeh & Lien (2009)	83,00%	N/D	N/D	N/D
Artigo Base – RF Completo	81,78%	37,53%	94,35%	0,753
Modelo Proposto – Limiar 0,50	81,78%	37,53%	94,35%	0,753
Modelo Proposto – Limiar 0,38 (KS)*	80,61%	45,21%	90,67%	0,753
Modelo Proposto – Limiar 0,30	77,55%	53,05%	84,50%	0,753

* Cenário recomendado. Fonte: elaboração própria a partir dos resultados do script R.

4. Por que Nossa Análise é a Vencedora da Rodada

Nesta seção justificamos por que nossa abordagem supera a solução do artigo base, destacando vantagens e desvantagens de forma transparente.

4.1. Vantagens

- Feature Engineering: as três variáveis criadas (SOMA_ATRASOS, USO_LIMITE_ATUAL, RAZAO_PAGAMENTO_ATUAL) comprimem informação relevante em formatos interpretáveis, facilitando explicação a gestores não técnicos sem perder poder preditivo.

- SMOTE: o artigo base ignorou o desbalanceamento da base (22% devedores), o que penaliza diretamente a sensibilidade. Nosso modelo ataca esse problema de forma estruturada, entregando +7,68 p.p. de sensibilidade no limiar 0,38.
- `ntree = 500`: o aumento de 100 para 500 árvores reduz a variância do modelo, tornando as previsões mais estáveis em casos limítrofes.
- Calibração de limiar: o pipeline entrega três cenários prontos (conservador, equilibrado e agressivo), permitindo que a instituição escolha conforme seu apetite de risco — algo prático e aplicável na realidade bancária.
- Em risco de crédito, detectar devedores (sensibilidade) é o objetivo mais importante. Acurácia geral tende a ser inflada pela classe majoritária (pagadores). Nosso modelo é mais útil na prática.
- Código comentado, com instalação condicional de pacotes, facilitando reprodução por qualquer usuário.

4.2. Desvantagens e Limitações

- Custo computacional maior: `ntree = 500` e SMOTE aumentam o tempo de execução em relação ao artigo base.
- A AUC final de 0,753 é idêntica ao artigo base, indicando que a capacidade discriminativa global não foi ampliada — os ganhos concentram-se na sensibilidade.
- Generalização: os resultados foram obtidos na base UCI Taiwan 2005 e podem requerer reajustes para outras bases de crédito.

4.3. Síntese

Nossa abordagem entrega um pipeline mais completo, robusto e orientado à aplicação prática do que o artigo base. O ganho de +7,68 p.p. em sensibilidade com limiar 0,38 — mantendo especificidade acima de 90% — é o resultado mais relevante da proposta. Em crédito, detectar o devedor é o que importa.