

Predição de Risco de Consumo de Substâncias Psicoativas: Uma Abordagem com Random Forest e Balanceamento Sintético de Classes

Arthur Faria Estrela¹, Ricardo Issa de Sousa¹, and Sávio Issa de Sousa¹

¹Sistemas de Informação, IF Goiano - Campus Urutaí

²Orientadora, Nattane Luiza da Costa

Dezembro de 2025

Resumo

O consumo de drogas é um fenômeno multifatorial influenciado por traços de personalidade e dados demográficos. A base de dados *Drug Consumption (Quantified)*, do repositório UCI, quantifica essas características, mas apresenta um desafio de classificação supervisionada devido ao severo desbalanceamento entre classes. O objetivo deste trabalho foi classificar indivíduos como "Usuários" ou "Não Usuários" de 18 substâncias distintas, utilizando escores de personalidade. Propõe-se uma estratégia de *Binary Relevance* empregando o algoritmo *Random Forest*, aprimorado pela técnica de superamostragem SMOTE (*Synthetic Minority Over-sampling Technique*) aplicada condicionalmente às classes minoritárias. Os resultados demonstraram que o uso de SMOTE elevou a métrica F1-Score para drogas com prevalência moderada, como LSD (68,35%) e Metanfetamina (46,77%), mas revelou limitações em substâncias extremamente raras como Crack e Heroína, onde a sensibilidade permaneceu baixa.

Palavras-chave: Mineração de Dados, Random Forest, SMOTE, Personalidade, Classificação Binária.

1 Introdução

O abuso de substâncias psicoativas representa um dos maiores desafios de saúde pública global. A identificação precoce de indivíduos com predisposição ao uso de drogas, baseada em traços psicológicos, pode auxiliar na criação de políticas de prevenção mais eficazes. A teoria do *Five Factor Model* (FFM) de personalidade — que engloba Neuroticismo, Extroversão, Abertura, Amabilidade e Conscienciosidade — tem sido amplamente utilizada para correlacionar perfis psicológicos a comportamentos de risco (Fehrman et al., 2015).

Neste contexto, a mineração de dados oferece ferramentas para modelar essas relações não lineares. A base de dados *Drug Consumption (Quantified)*, disponibilizada no UCI Machine Learning Repository, reúne dados de 1.885 respondentes. O principal obstáculo identificado nesta base é o desbalanceamento de classes, fazendo com que algoritmos padrão maximizem a acurácia global em detrimento da capacidade de detectar o usuário. Estudos anteriores, como o de Fehrman et al. (2017), exploraram essa base utilizando métodos clássicos, mas enfrentaram dificuldades na sensibilidade para drogas "pesadas".

Até onde se sabe, poucos estudos exploraram o impacto isolado de técnicas de balanceamento sintético como o SMOTE especificamente nesta base de dados para múltiplas substâncias simultaneamente. O presente trabalho visa mitigar essa limitação através de uma estratégia de *Binary Relevance*, utilizando o algoritmo *Random Forest* combinado com a técnica de balanceamento SMOTE. A hipótese é que a geração controlada de dados sintéticos para as classes minoritárias permitirá uma detecção mais precisa dos usuários de risco.

2 Materiais e Métodos

2.1 Base de Dados e Definição de Classes

A base de dados utilizada foi a *Drug Consumption (Quantified)* (Dua & Graff, 2019). As variáveis de entrada incluem dados demográficos e escores psicométricos normalizados. Para a modelagem, as classes originais de consumo foram binarizadas conforme a seguinte regra definida pelos autores para isolar o consumo recente:

- **Não Usuário:** Níveis CL0 e CL1 (Nunca usou ou usou há mais de uma década).
- **Usuário:** Níveis CL2 a CL6 (Uso na última década, ano, mês, semana ou dia).

Para atender à necessidade de transparência sobre o desbalanceamento, a Tabela 1 apresenta a distribuição das classes antes e depois da aplicação do SMOTE. Observa-se o fenômeno de "desbalanceamento inverso" em drogas lícitas (álcool, chocolate), onde a classe minoritária é a de não-usuários.


Tabela 1 – Distribuição das classes no conjunto de Treino antes e depois da aplicação do SMOTE

Droga	Antes: Não Usuário	Antes: Usuário	Depois: Não Usuário	Depois: Usuário	SMOTE Aplicado?
Alcohol	51	1358	51	1358	Não
Amphet	903	506	903	506	Não
Amyl	1132	276	1132	1132	Sim
Benzos	837	572	837	572	Não
Caff	28	1380	28	1380	Não
Cannabis	465	943	465	943	Não
Choc	26	1383	26	1383	Não
Coke	897	511	897	511	Não
Crack	1267	141	1267	1267	Sim
Ecstasy	849	559	849	559	Não
Heroin	1251	157	1251	1251	Sim
Ketamine	1149	260	1149	1149	Sim
Legalh	841	567	841	567	Não
LSD	995	414	995	995	Sim
Meth	1098	311	1098	1098	Sim
Mushrooms	893	516	893	516	Não
Nicotine	466	942	466	942	Não
VSA	1239	170	1239	1239	Sim

2.2 Estratégia de Modelagem

Diferente de abordagens multiclasse, adotou-se a estratégia de *Binary Relevance*, que consiste em decompor o problema de classificação de múltiplas drogas em 18 problemas de classificação binária independentes (um para cada substância). O fluxo de processamento dos dados está ilustrado na Figura 1.

Figura 1 – Fluxograma da metodologia proposta



O processamento foi implementado em linguagem R, utilizando os pacotes `caret` para o fluxo de treino, `randomForest` para o algoritmo de classificação e `themis` para a aplicação do SMOTE. O balanceamento via SMOTE foi aplicado exclusivamente ao conjunto de treino e apenas para as drogas cuja classe "Usuário" apresentava proporção inferior a 30%, a fim de evitar *overfitting* em substâncias com alta prevalência. Após o balanceamento, o modelo *Random Forest* (100 árvores) foi treinado e validado com validação cruzada ($k = 5$).

2.3 Métricas de Avaliação

O desempenho dos modelos foi avaliado no conjunto de teste utilizando as métricas de Sensibilidade, Especificidade e F1-Score, calculadas conforme as Equações 1, 2 e 3:

$$Sensibilidade = \frac{VP}{VP + FN} \quad (1)$$

$$Especificidade = \frac{VN}{VN + FP} \quad (2)$$

$$F1-Score = 2 \cdot \frac{Preciso \cdot Sensibilidade}{Preciso + Sensibilidade} \quad (3)$$

Onde: VP são Verdadeiros Positivos, VN são Verdadeiros Negativos, FP são Falsos Positivos e FN são Falsos Negativos.

3 Resultados e Discussão

Os resultados de desempenho para cada substância, baseados nas predições do conjunto de teste, estão apresentados na Tabela 2.

Tabela 2 – Métricas de desempenho nos dados de teste

Droga	Método	Acurácia (%)	Sensibilidade (%)	Especificidade (%)	F1-Score (%)
Alcohol	RF Padrão	96,58	100,00	0,00	98,26
Amphet	RF Padrão	71,58	56,55	80,00	58,82
Amyl	RF + SMOTE	81,45	32,61	93,37	40,82
Benzos	RF Padrão	69,23	52,63	80,58	58,14
Caff	RF Padrão	98,08	100,00	0,00	99,03
Cannabis	RF Padrão	81,88	88,85	67,74	86,78
Choc	RF Padrão	98,29	100,00	0,00	99,14
Coke	RF Padrão	69,08	43,53	83,61	50,51
Crack	RF + SMOTE	87,21	17,02	95,02	21,05
Ecstasy	RF Padrão	74,84	67,74	79,51	68,11
Heroin	RF + SMOTE	87,63	25,00	95,44	30,95
Ketamine	RF + SMOTE	80,77	30,23	92,15	36,62
Legalh	RF Padrão	81,24	72,49	87,14	75,69
LSD	RF + SMOTE	81,20	69,34	86,10	68,35
Meth	RF + SMOTE	77,14	45,63	86,03	46,77
Mushrooms	RF Padrão	75,64	64,33	82,15	65,87
Nicotine	RF Padrão	71,43	85,35	43,23	80,00
VSA	RF + SMOTE	85,47	26,79	93,45	30,61

3.1 Análise das Drogas e Comparação com a Literatura

Substâncias com desbalanceamento invertido, como Álcool, Cafeína e Chocolate, apresentaram sensibilidade de 100% e especificidade de 0%. Isso indica que o modelo classificou todas as instâncias como "Usuário", o que é estatisticamente esperado dado que quase a totalidade da amostra consome essas substâncias.

Ao comparar com a literatura, os resultados obtidos mostram-se competitivos e, em alguns casos, superiores. Fehrman et al. (2015) relataram sensibilidade média em torno de 75-80% para Cannabis usando redes neurais e SVM. O modelo proposto neste estudo atingiu uma sensibilidade superior de 88,85% para a mesma substância.

Observa-se que o SMOTE foi determinante para melhorar a detecção de usuários em drogas de baixa prevalência, como LSD ($F1 = 68,35\%$) e Metanfetamina ($F1 = 46,77\%$). Entretanto, para substâncias extremamente raras como Crack (Sensibilidade = 17,02%) e Heroína (Sensibilidade = 25,00%), o balanceamento não foi suficiente para compensar a escassez absoluta de exemplos positivos. Este comportamento corrobora estudos em outras áreas, onde o SMOTE perde eficácia quando o número absoluto de amostras da classe minoritária é demasiadamente baixo para formar vizinhanças sintéticas robustas (Chawla et al., 2002).

4 Conclusão

Este trabalho evidenciou que o uso de *Random Forest* combinado com SMOTE manual é uma estratégia eficaz para drogas de prevalência moderada, superando desafios de desbalanceamento em substâncias como LSD. Contudo, os resultados para drogas muito raras indicam que apenas o balanceamento sintético não resolve o problema da falta de informação latente nos dados. Embora a acurácia global nessas classes tenha sido alta (acima de 87%), esse valor é inflacionado pela especificidade (acertos de não-usuários). A baixa sensibilidade nestes casos específicos sugere a necessidade de coletar mais dados reais ou testar novas arquiteturas de aprendizado profundo para capturar padrões mais sutis.

Referências

- Dua, D. and Graff, C. (2019). UCI Machine Learning Repository. Irvine, CA: University of California, School of Information and Computer Science.
- Fehrman, E., et al. (2015). The Five Factor Model of Personality and Evaluation of Drug Consumption Risk. In *Data Science* (pp. 25-42). Springer.
- Fehrman, E., et al. (2017). Personality Traits and Drug Consumption: A Story Told by Data. *arXiv preprint arXiv:1706.01235*.
- Kuhn, M. (2008). Building Predictive Models in R Using the caret Package. *Journal of Statistical Software*, 28(5).
- Chawla, N. V., et al. (2002). SMOTE: synthetic minority over-sampling technique. *Journal of artificial intelligence research*, 16, 321-357.