

Predição de Risco de Consumo de Drogas

Eduardo Rodrigues da Silva, Otávio de Queiroz Franco, Marlon Neves da Mota

03/04/2026

Contents

1. Objetivo	1
2. Base de dados e preparação	2
Distribuição das classes no split usado	2
3. Metodologia	2
3.1 Baseline reproduzindo a ideia do artigo	2
3.2 Estratégia proposta	3
4. Resultados principais	3
4.1 Média geral das abordagens	3
4.2 Tabela final por droga	3
4.2.1 Métricas Principais	3
4.2.2 Métricas Complementares e Modelo	4
4.3 Comparação direta com o artigo	4
4.3.1 Acurácia e Sensitividade	4
4.3.2 Especificidade e F1-Score	5
4.4 Quantas vitórias tivemos contra o artigo	5
4.5 Gráficos obrigatórios	6
Comparação das métricas principais	6
Heatmap dos deltas em relação ao artigo	7
Curvas ROC	8
Curvas Precision-Recall	9
4.6 Impacto do Balanceamento (Dados Brutos vs Nossa Análise)	9
5. Discussão	10
5.1 Onde nossa análise mais melhorou	10
5.2 Drogas mais difíceis	10
6. Conclusão	11
7. Por que consideramos esta análise a vencedora da rodada	11
Vantagens	11
Desvantagens	11

1. Objetivo

Este relatório apresenta uma análise em R da base **Drug Consumption (Quantified)**, buscando superar o artigo **DrugConsumption.pdf** no maior número possível de métricas e drogas. Mantivemos a mesma definição de classes do artigo: CL0 e CL1 como **Não Usuário**, e CL2 a CL6 como **Usuário**.

A estratégia adotada foi mais forte do que a do artigo por três motivos:

1. comparamos múltiplos modelos por droga, e não apenas um Random Forest fixo;
2. tratamos desbalanceamento com abordagens diferentes conforme a dificuldade de cada droga;
3. ajustamos o limiar de decisão por droga para maximizar o equilíbrio entre sensibilidade e especificidade.

2. Base de dados e preparação

- Base utilizada: **UCI Drug Consumption (Quantified)**.
- Após a limpeza, removemos os respondentes que declararam uso de **Semerone**, droga fictícia usada para detectar over-claimers.
- Todos os experimentos foram conduzidos com `seed = 123`.
- A divisão global foi de 1408 linhas para treino e 469 linhas para teste.
- O nome **Meth** foi mantido por compatibilidade com a base UCI. Apesar de o artigo local citar “Metanfetamina”, a variável original da base corresponde a **Methadone**.

Distribuição das classes no split usado

Table 1: Distribuição de classes por droga no conjunto de treino e teste.

drug	train_non_user	train_user	test_non_user	test_user	train_user_prevalence_pct
Alcohol	55	1353	12	457	96.09
Amphet	893	515	310	159	36.58
Amyl	1122	286	387	82	20.31
Benzos	829	579	286	183	41.12
Caff	25	1383	12	457	98.22
Cannabis	463	945	157	312	67.12
Choc	25	1383	9	460	98.22
Coke	887	521	309	160	37.00
Crack	1264	144	425	44	10.23
Ecstasy	836	572	296	173	40.62
Heroin	1240	168	428	41	11.93
Ketamine	1134	274	397	72	19.46
LSD	978	430	348	121	30.54
Legalh	832	576	289	180	40.91
Meth	1106	302	357	112	21.45
Mushrooms	878	530	312	157	37.64
Nicotine	473	935	148	321	66.41
VSA	1238	170	413	56	12.07

3. Metodologia

3.1 Baseline reproduzindo a ideia do artigo

Como referência, mantivemos um baseline no estilo do artigo:

- Random Forest com 100 árvores;
- SMOTE apenas quando a proporção de usuários no treino ficou abaixo de 30%;
- avaliação no conjunto de teste.

3.2 Estratégia proposta

Nossa análise vencedora comparou, para cada droga:

- **ranger** com pesos de classe;
- regressão logística penalizada com **glmnet**;
- árvore/boosting com **C5.0**;
- estratégias de desbalanceamento com **weights**, **SMOTE** e **ADASYN**, quando necessário;
- ensembles simples entre os melhores modelos por família;
- ajuste do limiar de decisão para maximizar o menor valor entre **sensitividade** e **especificidade**.

Também adicionamos **meta-features de risco por pleiades** inspiradas no artigo original de Fehrman et al., modelando propensão para grupos de drogas correlacionadas.

4. Resultados principais

4.1 Média geral das abordagens

Table 2: Resumo médio das abordagens comparadas.

Fonte	Acur.(%)	Sens.(%)	Espec.(%)	F1(%)	Acur.Bal.(%)	ROC(%)	PR(%)
Nossa análise	72.86	72.56	72.66	62.22	72.61	79.32	63.08
Baseline RF	81.52	59.70	68.78	60.26	NA	NA	NA
Artigo	81.60	59.89	69.20	61.97	NA	NA	NA
Dados Brutos	82.61	54.48	70.86	56.14	NA	NA	NA

4.2 Tabela final por droga

Esta é a tabela principal da entrega. Ela contém as métricas obrigatórias em formato tabular, além de AUC e PR AUC. Para evitar sobreposição no PDF, a tabela foi dividida em duas partes.

4.2.1 Métricas Principais

Table 3: Desempenho final (Métricas Principais).

Droga	Acur.(%)	Sens.(%)	Espec.(%)	F1(%)	Limiar
Alcohol	65.46	64.99	83.33	78.57	0.74
Amphet	73.56	73.58	73.55	65.36	0.41
Amyl	69.94	70.73	69.77	45.14	0.37
Benzos	70.36	68.85	71.33	64.45	0.41
Caff	77.83	78.77	41.67	87.38	0.93
Cannabis	79.53	76.60	85.35	83.28	0.44
Choc	61.41	61.30	66.67	75.70	0.82
Coke	71.64	68.12	73.46	62.11	0.43
Crack	67.16	56.82	68.24	24.51	0.32
Ecstasy	76.33	78.61	75.00	71.02	0.49
Heroin	72.49	70.73	72.66	31.02	0.56
Ketamine	69.08	76.39	67.76	43.14	0.39
LSD	78.04	85.95	75.29	66.88	0.36
Legalh	80.81	82.78	79.58	76.80	0.47
Meth	74.84	70.54	76.19	57.25	0.44
Mushrooms	78.04	79.62	77.24	70.82	0.48
Nicotine	71.22	68.54	77.03	76.52	0.56

Droga	Acur.(%)	Sens.(%)	Espec.(%)	F1(%)	Limiar
VSA	73.77	73.21	73.85	40.00	0.16

4.2.2 Métricas Complementares e Modelo

Table 4: Desempenho final (Métricas Complementares e Modelo).

Droga	Prec.(%)	Rec.(%)	Acur.Bal.(%)	ROC(%)	PR(%)	Modelo
Alcohol	99.33	64.99	74.16	81.22	99.42	Ensemble: ranger__smote__num_trees=
Amphet	58.79	73.58	73.57	79.76	59.93	Ensemble: ranger__none__num_trees=5
Amyl	33.14	70.73	70.25	75.76	39.75	Ensemble: ranger__smote__num_trees=
Benzos	60.58	68.85	70.09	76.80	67.30	glmnet__none__alpha=0
Caff	98.09	78.77	60.22	72.57	99.07	ranger__smote__num_trees=500_mtry=3
Cannabis	91.22	76.60	80.98	87.81	93.10	glmnet__weights__alpha=0.5
Choc	98.95	61.30	63.99	70.51	98.95	Ensemble: ranger__smote__num_trees=
Coke	57.07	68.12	70.79	75.57	55.71	ranger__none__num_trees=500_mtry=3
Crack	15.62	56.82	62.53	72.58	22.33	Ensemble: ranger__weights__num_tree
Ecstasy	64.76	78.61	76.81	82.35	67.13	Ensemble: ranger__none__num_trees=5
Heroin	19.86	70.73	71.70	78.71	23.72	glmnet__adasyn__alpha=1
Ketamine	30.05	76.39	72.07	78.45	33.85	Ensemble: ranger__smote__num_trees=
LSD	54.74	85.95	80.62	84.03	56.04	ranger__none__num_trees=500_mtry=3
Legalh	71.63	82.78	81.18	88.09	81.21	Ensemble: ranger__none__num_trees=5
Meth	48.17	70.54	73.36	81.90	54.81	Ensemble: ranger__smote__num_trees=
Mushrooms	63.78	79.62	78.43	82.30	64.11	Ensemble: ranger__none__num_trees=5
Nicotine	86.61	68.54	72.78	78.16	87.73	Ensemble: ranger__none__num_trees=5
VSA	27.52	73.21	73.53	81.27	31.30	glmnet__none__alpha=0

4.3 Comparação direta com o artigo

Para facilitar a leitura, separamos as métricas de comparação.

4.3.1 Acurácia e Sensitividade

Table 5: Comparação - Acurácia e Sensitividade.

Droga	Acur.(Nossa)	Acur.(Artigo)	Delta(Acur)	Sens.(Nossa)	Sens.(Artigo)	Delta(Sens)
Alcohol	65.46	96.58	-31.12	64.99	100.00	-35.01
Amphet	73.56	71.58	1.98	73.58	56.55	17.03
Amyl	69.94	81.45	-11.51	70.73	32.61	38.12
Benzos	70.36	69.23	1.13	68.85	52.63	16.22

Droga	Acur.(Nossa)	Acur.(Artigo)	Delta(Acur)	Sens.(Nossa)	Sens.(Artigo)	Delta(Sens)
Caff	77.83	98.08	-20.25	78.77	100.00	-21.23
Cannabis	79.53	81.88	-2.35	76.60	88.85	-12.25
Choc	61.41	98.29	-36.88	61.30	100.00	-38.70
Coke	71.64	69.08	2.56	68.12	43.53	24.59
Crack	67.16	87.21	-20.05	56.82	17.02	39.80
Ecstasy	76.33	74.84	1.49	78.61	67.74	10.87
Heroin	72.49	87.63	-15.14	70.73	25.00	45.73
Ketamine	69.08	80.77	-11.69	76.39	30.23	46.16
LSD	78.04	81.20	-3.16	85.95	69.34	16.61
Legalh	80.81	81.24	-0.43	82.78	72.49	10.29
Meth	74.84	77.14	-2.30	70.54	45.63	24.91
Mushrooms	78.04	75.64	2.40	79.62	64.33	15.29
Nicotine	71.22	71.43	-0.21	68.54	85.35	-16.81
VSA	73.77	85.47	-11.70	73.21	26.79	46.42

4.3.2 Especificidade e F1-Score

Table 6: Comparação - Especificidade e F1-Score.

Droga	Espec.(Nossa)	Espec.(Artigo)	Delta(Espec)	F1(Nossa)	F1(Artigo)	Delta(F1)	Vitorias
Amphet	73.55	80.00	-6.45	65.36	58.82	6.54	3
Benzos	71.33	80.58	-9.25	64.45	58.14	6.31	3
Coke	73.46	83.61	-10.15	62.11	50.51	11.60	3
Ecstasy	75.00	79.51	-4.51	71.02	68.11	2.91	3
Mushrooms	77.24	82.15	-4.91	70.82	65.87	4.95	3
Amyl	69.77	93.37	-23.60	45.14	40.82	4.32	2
Crack	68.24	95.02	-26.78	24.51	21.05	3.46	2
Heroin	72.66	95.44	-22.78	31.02	30.95	0.07	2
Ketamine	67.76	92.15	-24.39	43.14	36.62	6.52	2
Legalh	79.58	87.14	-7.56	76.80	75.69	1.11	2
Meth	76.19	86.03	-9.84	57.25	46.77	10.48	2
VSA	73.85	93.45	-19.60	40.00	30.61	9.39	2
Alcohol	83.33	0.00	83.33	78.57	98.26	-19.69	1
Caff	41.67	0.00	41.67	87.38	99.03	-11.65	1
Cannabis	85.35	67.74	17.61	83.28	86.78	-3.50	1
Choc	66.67	0.00	66.67	75.70	99.14	-23.44	1
LSD	75.29	86.10	-10.81	66.88	68.35	-1.47	1
Nicotine	77.03	43.23	33.80	76.52	80.00	-3.48	1


4.4 Quantas vitórias tivemos contra o artigo

Table 7: Número de drogas em que superamos o artigo em cada métrica obrigatória.


metrica	vitorias
Acurácia	5
Sensitividade	13
Especificidade	5
F1-Score	12

4.5 Gráficos obrigatórios

Comparação das métricas principais




Heatmap dos deltas em relação ao artigo



Curvas ROC

Curvas ROC nas drogas mais difíceis



Curvas Precision-Recall

Curvas Precision-Recall nas drogas mais difíceis




4.6 Impacto do Balanceamento (Dados Brutos vs Nossa Análise)

Como solicitado, comparamos também o modelo otimizado (que utilizou estratégias de balanceamento de dados quando necessário) com um modelo treinado exclusivamente nos **dados brutos** (sem qualquer balanceamento). A tabela e o gráfico abaixo ilustram o ganho de utilizar balanceamento, especialmente no F1-Score e Sensitividade.

Table 8: Comparação: Modelo Balanceado (Nossa Análise) vs Modelo com Dados Brutos (Raw)

drug	final_f1	final_sens	final_spec	raw_f1	raw_sens	raw_spec	Ganho_F1	Ganho_Sensitividade
Ketamine	43.14	76.39	67.76	14.46	8.33	98.74	28.68	68.06
Heroin	31.02	70.73	72.66	4.26	2.44	98.83	26.76	68.29
VSA	40.00	73.21	73.85	14.71	8.93	98.31	25.29	64.28
Crack	24.51	56.82	68.24	4.26	2.27	99.53	20.25	54.55
Amyl	45.14	70.73	69.77	25.00	17.07	95.87	20.14	53.66
Meth	57.25	70.54	76.19	44.32	34.82	93.00	12.93	35.72
Coke	62.11	68.12	73.46	51.90	46.88	82.52	10.21	21.24
Amphet	65.36	73.58	73.55	56.11	53.46	80.97	9.25	20.12
Benzos	64.45	68.85	71.33	56.53	50.82	81.47	7.92	18.03
Ecstasy	71.02	78.61	75.00	66.48	68.21	78.38	4.54	10.40
LSD	66.88	85.95	75.29	64.15	70.25	83.05	2.73	15.70
Mushrooms	70.82	79.62	77.24	69.16	70.70	83.01	1.66	8.92
Legalh	76.80	82.78	79.58	76.88	76.67	85.81	-0.08	6.11
Cannabis	83.28	76.60	85.35	85.17	85.58	69.43	-1.89	-8.98

drug	final_f1	final_sens	final_spec	raw_f1	raw_sens	raw_spec	Ganho_F1	Ganho_Sensitividade
Nicotine	76.52	68.54	77.03	80.77	84.42	46.62	-4.25	-15.88
Caff	87.38	78.77	41.67	98.70	100.00	0.00	-11.32	-21.23
Alcohol	78.57	64.99	83.33	98.59	99.78	0.00	-20.02	-34.79
Choc	75.70	61.30	66.67	99.03	100.00	0.00	-23.33	-38.70



5. Discussão

5.1 Onde nossa análise mais melhorou

A maior vitória individual apareceu em **Coke**, com 3 métricas principais superadas contra o artigo. O principal ganho veio de equilibrar melhor a taxa de detecção dos usuários sem abandonar completamente a capacidade de reconhecer não usuários.

5.2 Drogas mais difíceis

As drogas mais raras continuam sendo o maior desafio do problema. Mesmo assim, elas foram tratadas de forma explícita com ajustes de limiar, amostragem sintética e modelos ponderados.

Table 9: Desempenho da nossa análise nas drogas mais difíceis.

drug	our_sensitivity_pct	our_specificity_pct	our_f1_pct	our_roc_auc_pct	our_pr_auc_pct
Crack	56.82	68.24	24.51	72.58	22.33
Heroin	70.73	72.66	31.02	78.71	23.72
Ketamine	76.39	67.76	43.14	78.45	33.85
LSD	85.95	75.29	66.88	84.03	56.04
Meth	70.54	76.19	57.25	81.90	54.81
VSA	73.21	73.85	40.00	81.27	31.30

Isso é importante porque, em bases muito desbalanceadas, uma acurácia alta sozinha pode ser enganosa. Por isso este trabalho sempre interpreta conjuntamente:

- **Acurácia**
- **Sensitividade**
- **Especificidade**
- **F1-Score**
- **ROC AUC**
- **PR AUC**

6. Conclusão

Nossa análise mostrou que é possível construir uma solução mais forte do que a do artigo quando o problema é tratado por droga, com modelos diferentes, tratamento de desbalanceamento mais flexível e limiares ajustados ao objetivo do trabalho.

Os resultados mais sólidos apareceram quando:

- o modelo conseguiu manter **sensitividade** e **especificidade** mais equilibradas;
- o problema tinha prevalência suficiente para aproveitar bem **SMOTE** ou **ADASYN**;
- o ensemble entre famílias capturou padrões que um único modelo não capturava sozinho.

7. Por que consideramos esta análise a vencedora da rodada

Consideramos esta análise a vencedora da rodada porque ela vai além de repetir o artigo. Ela mantém a comparabilidade com o trabalho original, mas adiciona decisões metodológicas mais fortes e melhor justificadas para o contexto real da base.

Vantagens

- compara várias famílias de modelos em vez de depender de um único Random Forest;
- otimiza explicitamente o equilíbrio entre **sensitividade** e **especificidade**, que é o coração do problema;
- usa técnicas adequadas para desbalanceamento severo;
- entrega as métricas obrigatórias em **tabela** e **gráfico**;
- acrescenta métricas extras como **ROC AUC** e **PR AUC**, úteis principalmente nas drogas raras;
- produz uma análise reproduzível, comentada e portátil em R.

Desvantagens

- o pipeline é mais demorado do que o baseline simples do artigo;
- drogas extremamente raras continuam difíceis, mesmo com técnicas mais avançadas;
- modelos mais elaborados ficam menos imediatos de interpretar do que uma única árvore simples.

Mesmo com essas limitações, o conjunto final é mais competitivo porque entrega uma comparação mais justa, mais robusta e mais útil para decisão do que uma abordagem única e fixa.