

Análise de Dados: Gallstone Disease Prediction

Necessidade real de 10 variáveis, custo-benefício e plausibilidade clínica

31/03/2026

Contents

Introdução	1
Dataset e desenho analítico	2
Gráficos exploratórios	2
Auditoria científica das variáveis	5
Relevância univariada (80/20)	5
Redundância forte entre variáveis (80/20)	6
Painéis candidatos e critério de escolha	7
Conclusão objetiva	9
Por que o painel recomendado faz sentido	9
Justificativa feature por feature	9
Desempenho dos 9 modelos no painel de referência interno	10
Cenário 80/20	10
Cenário 70/30	10
Painel recomendado (revalidado com 10-fold CV)	10
Faz sentido com a vida real?	17
Limitações	18
Referências	18

Introdução

Este relatório responde a uma pergunta metodológica e clínica: **o corte fixo em 10 variáveis realmente é necessário nesta base?**


Toda a análise foi conduzida de forma **data-driven**, sem usar o artigo original como baseline de comparação. O foco aqui é comparar painéis cumulativos e painéis podados por redundância, sempre pesando desempenho, custo operacional de coleta e plausibilidade clínica.

Dataset e desenho analítico


- Base: Gallstone Disease Prediction (UCI).
- Amostra: 319 instâncias e 38 preditoras.
- Variável-alvo: **Gallstone**.
- Painéis candidatos: **full_38**, **raw_top_k** e **pruned_top_k**.
- Pannel de referência interno: pannel bruto com 10 variáveis derivado diretamente do ranking de importância do treino.
- Triagem dos painéis: 5-fold CV com **tuneLength** = 3.
- Revalidação final do pannel de referência e do pannel recomendado: 10-fold CV com **tuneLength** = 5.


Pannel de referencia interno: **raw_top_10**. Features 80/20: CRP, VitaminD, ECF_TBW, ECW, BM, TBFR, VMA, LM, HFA, VFA. Features 70/30: CRP, VitaminD, ECW, BM, TBFR, AST, ECF_TBW, LM, HDL, HFA.

Gráficos exploratórios




Distribuicao por Genero e Status de Calculo Biliar





Matriz de Correlacao entre Variaveis Numericas



Auditoria científica das variáveis

Relevância univariada (80/20)

As comparações univariadas ajudam a separar sinal plausível de ruído antes da seleção multivariada. Para variáveis numéricas foi usado Wilcoxon; para categóricas, Fisher ou qui-quadrado, conforme a frequência esperada.

Table 1: Top 15 variáveis por relevância univariada no treino 80/20

Feature	Grupo	Tipo	Teste	Estatística	Pvalor	Efeito
CRP	Laboratorio	Numerica	Wilcoxon	3551.0	0.0000	-1.2800
VitaminD	Laboratorio	Numerica	Wilcoxon	11638.5	0.0000	8.5000
AST	Laboratorio	Numerica	Wilcoxon	10625.0	0.0000	3.0000
TBFR	Bioimpedancia	Numerica	Wilcoxon	6213.5	0.0008	-5.4100
LM	Bioimpedancia	Numerica	Wilcoxon	10140.0	0.0010	5.4000
HFA	HFA	Categorica	Fisher	NA	0.0011	0.1309
BM	Bioimpedancia	Numerica	Wilcoxon	10093.0	0.0013	0.3000

Feature	Grupo	Tipo	Teste	Estatistica	Pvalor	Efeito
TFC	Bioimpedancia	Numerica	Wilcoxon	6468.5	0.0036	-4.5000
ECF_TBW	Bioimpedancia	Numerica	Wilcoxon	9787.5	0.0069	0.0000
VFA	Bioimpedancia	Numerica	Wilcoxon	6630.5	0.0084	-2.0700
HDL	Laboratorio	Numerica	Wilcoxon	6631.5	0.0084	-3.0000
ECW	Bioimpedancia	Numerica	Wilcoxon	9728.5	0.0095	0.5000
Hyperlipidemia	Historia	Categorica	Fisher	NA	0.0140	0.0472
HGB	Laboratorio	Numerica	Wilcoxon	9509.0	0.0262	0.5000
BMI	Antropometria	Numerica	Wilcoxon	7057.5	0.0557	-1.4000

Redundância forte entre variáveis (80/20)

Em medicina aplicada, duas medidas quase equivalentes só devem coexistir se o ganho justificar o custo extra. Nesta base, várias variáveis de composição corporal andam juntas.




Table 2: Pares com $|r| \geq 0.85$ no treino 80/20

Feature1	Feature2	Correlacao
TBFR	LM	-0.994
BMI	Obesity	0.922
TBW	MM	0.913
BMI	TFC	0.908
TBW	ECW	0.894

Feature1	Feature2	Correlacao
ICW	MM	0.888
Weight	VFA	0.879
TFC	VFA	0.868
TBFR	TFC	0.866
LM	TFC	-0.863
TC	LDL	0.859
Obesity	TFC	0.858

Table 3: Clusters de redundância no treino 80/20

Cluster	Tamanho	Feature
C01	1	Age
C02	1	Height
C03	7	BMI, LM, Obesity, TBFR, TFC, VFA, Weight
C04	4	ECW, ICW, MM, TBW
C05	1	ECF_TBW
C06	1	Protein
C07	1	VFR
C08	1	BM
C09	1	VMA
C10	1	Glucose
C11	2	LDL, TC
C12	1	HDL
C13	1	Triglyceride
C14	1	AST
C15	1	ALT
C16	1	ALP
C17	1	Creatinine
C18	1	GFR
C19	1	CRP
C20	1	HGB
C21	1	VitaminD

Painéis candidatos e critério de escolha

- **full_38**: todas as variáveis.
- **raw_top_k**: ranking bruto de importância do Random Forest com k de 3 a 15.
- **pruned_top_k**: ranking após remover redundância forte, com k de 3 a 15.
- **raw_top_10**: painel de referência interno usado para testar se um corte fixo de 10 variáveis faz sentido nos dados.

Para viabilizar a comparação extensa de painéis, a **triagem** usou 5-fold CV com **tuneLength** = 3. Depois da escolha do painel, o **painel de referência interno** e o **painel recomendado** foram rerodados com 10-fold CV e **tuneLength** = 5 para a leitura final.

Regra de decisão usada:

- Elegível se ficar até 1 ponto percentual abaixo da melhor AUC média.
- Elegível se ficar até 2 pontos abaixo do melhor F1 médio.

- Elegível se ficar até 3 pontos abaixo da melhor sensibilidade média.
- Entre os elegíveis, vence o menor custo operacional.
- Empate: menor número de variáveis; novo empate: maior sensibilidade.





Table 4: Resumo global dos painéis candidatos

Painel_Base	Acuracia	Sensibilidade	F1	AUC	N_Features	Custo_Total	Elegivel	Recomendado
pruned_top_12	73.43	80.42	73.97	87.09	12	10.0	TRUE	FALSE
pruned_top_09	72.74	77.90	71.71	87.08	9	9.5	FALSE	FALSE
pruned_top_11	74.41	81.60	75.22	87.04	11	10.0	TRUE	TRUE
pruned_top_13	73.30	79.69	73.87	86.98	13	10.5	TRUE	FALSE
raw_top_12	72.56	74.94	71.69	86.88	12	9.5	FALSE	FALSE
raw_top_10	71.16	74.13	70.03	86.78	10	9.0	FALSE	FALSE
raw_top_11	72.39	74.77	71.20	86.74	11	9.5	FALSE	FALSE
pruned_top_10	71.74	76.10	70.61	86.61	10	9.5	FALSE	FALSE
pruned_top_14	71.63	74.42	69.42	86.60	14	10.5	FALSE	FALSE
raw_top_13	72.50	75.00	71.63	86.55	13	9.5	FALSE	FALSE
pruned_top_15	71.34	74.25	69.32	86.55	15	10.5	FALSE	FALSE
pruned_top_08	71.28	74.54	69.78	86.46	8	9.0	FALSE	FALSE
raw_top_14	73.56	77.09	73.07	86.44	14	10.0	FALSE	FALSE
raw_top_15	74.56	80.55	75.17	86.42	15	10.5	TRUE	FALSE
raw_top_07	72.10	80.38	73.16	85.51	7	5.0	FALSE	FALSE

Conclusão objetiva

O painel pruned_top_11 manteve 11 features e mostrou melhor equilibrio entre desempenho medio, estabilidade e custo-beneficio do que assumir um corte fixo e universal de 10 variaveis.

Painel recomendado: **pruned_top_11**. Features 80/20: CRP, VitaminD, ECF_TBW, ECW, BM, TBFR, VMA, HFA, AST, Protein, Hyperlipidemia. Features 70/30: CRP, VitaminD, ECW, TBFR, AST, ECF_TBW, HDL, HFA, Hyperlipidemia, Gender, Protein.

Custo medio do painel recomendado: **10.00**. Custo 80/20: **10**. Custo 70/30: **10**.

Por que o painel recomendado faz sentido

O painel recomendado foi interpretado como ferramenta de triagem, nao como substituto de ultrassonografia ou avaliacao clinica especializada.

Na pratica, o custo foi calculado por origem da informacao: Historia=1 + Laboratorio=2 + Bioimpedancia=3 + HFA=4 .

Isso permite comparar nao apenas desempenho estatistico, mas tambem o esforco humano e estrutural para coletar o painel: Historia + Laboratorio + Bioimpedancia + HFA .

Em linha com o NIDDK, fatores ligados a obesidade, metabolismo lipidico e diabetes fazem sentido biologico para colelitias, mesmo quando uma variavel nao lidera sozinha o ranking de importancia.

Justificativa feature por feature

- **CRP**: PCR capta inflamacao sistematica e foi uma das variaveis mais consistentes nos estudos.
- **VitaminD**: deficiencia de vitamina D foi destacada nos estudos e tem plausibilidade via estase biliar.
- **ECF_TBW**: a razao entre agua extracelular e agua corporal total resume o balanço hidrico sem usar duas medidas separadas.
- **ECW**: agua extracelular captura distribuicao hidrica e inflamada da composicao corporal.
- **BM**: massa ossea aparece como proxy de composicao corporal global e estado nutricional.

- **TBFR:** taxa de gordura corporal total expressa adiposidade, ligada a síndrome metabólica e litogênese.
- **VMA:** área muscular visceral pode representar fenotipo corporal e distribuição de massa metabólica.
- **HFA:** acúmulo de gordura hepática conecta resistência insulínica, esteatose e bile litogênica.
- **AST:** AST é um marcador hepatocelular inespecífico com plausibilidade em doença hepatobiliar.
- **Protein:** conteúdo proteico corporal atua como marcador indireto de composição e estado nutricional.
- **Hyperlipidemia:** hiperlipidemia tem plausibilidade biológica direta por aumentar o ambiente litogênico.

Desempenho dos 9 modelos no painel de referência interno

Cenário 80/20

Table 5: Painel de referência interno - cenário 80/20 (revalidado com 10-fold CV)

Modelo	Acuracia	Sensibilidade	Especificidade	Precisao	F1	AUC	Acc_CV
Logistic Regression	84.13	93.75	74.19	78.95	85.71	90.62	77.31
Random Forest	85.71	87.50	83.87	84.85	86.15	92.04	77.35
AdaBoost	11.11	6.25	16.13	7.14	6.67	93.45	23.00
Gradient Boosting	87.30	93.75	80.65	83.33	88.24	92.94	77.02
MLP	85.71	96.88	74.19	79.49	87.32	91.83	78.52
SVM Radial	82.54	93.75	70.97	76.92	84.51	88.10	74.22
Decision Tree	79.37	90.62	67.74	74.36	81.69	86.04	70.28
Naive Bayes	60.32	25.00	96.77	88.89	39.02	93.45	64.83
KNN	74.60	87.50	61.29	70.00	77.78	90.47	71.54

Cenário 70/30

Table 6: Painel de referência interno - cenário 70/30 (revalidado com 10-fold CV)

Modelo	Acuracia	Sensibilidade	Especificidade	Precisao	F1	AUC	Acc_CV
Logistic Regression	82.11	89.58	74.47	78.18	83.50	88.43	78.16
Random Forest	78.95	87.50	70.21	75.00	80.77	86.15	78.06
AdaBoost	27.37	10.42	44.68	16.13	12.66	80.59	20.53
Gradient Boosting	74.74	85.42	63.83	70.69	77.36	83.42	79.45
MLP	82.11	97.92	65.96	74.60	84.68	87.68	80.77
SVM Radial	83.16	85.42	80.85	82.00	83.67	89.27	74.51
Decision Tree	69.47	77.08	61.70	67.27	71.84	68.68	78.60
Naive Bayes	67.37	41.67	93.62	86.96	56.34	85.37	70.04
KNN	80.00	89.58	70.21	75.44	81.90	90.16	66.94


Painel recomendado (revalidado com 10-fold CV)


Table 7: Painei recomendado - cenário 80/20

Modelo	Acuracia	Sensibilidade	Especificidade	Precisao	F1	AUC	Acc_CV
Logistic Regression	92.06	96.88	87.10	88.57	92.54	90.62	79.31
Random Forest	88.89	93.75	83.87	85.71	89.55	94.76	78.51
AdaBoost	12.70	9.38	16.13	10.34	9.84	93.95	21.46
Gradient Boosting	84.13	84.38	83.87	84.38	84.38	90.73	79.69
MLP	85.71	96.88	74.19	79.49	87.32	90.42	78.54
SVM Radial	84.13	90.62	77.42	80.56	85.29	92.14	78.94
Decision Tree	79.37	90.62	67.74	74.36	81.69	86.04	68.72
Naive Bayes	84.13	84.38	83.87	84.38	84.38	93.25	75.72
KNN	80.95	90.62	70.97	76.32	82.86	92.04	70.77


Table 8: Painei recomendado - cenário 70/30

Modelo	Acuracia	Sensibilidade	Especificidade	Precisao	F1	AUC	Acc_CV
Logistic Regression	82.11	93.75	70.21	76.27	84.11	88.96	78.20
Random Forest	77.89	91.67	63.83	72.13	80.73	87.19	78.10
AdaBoost	24.21	10.42	38.30	14.71	12.20	82.62	20.99
Gradient Boosting	76.84	87.50	65.96	72.41	79.25	84.31	78.54
MLP	75.79	91.67	59.57	69.84	79.28	87.77	81.28
SVM Radial	81.05	89.58	72.34	76.79	82.69	86.79	75.47
Decision Tree	65.26	87.50	42.55	60.87	71.79	68.02	79.43
Naive Bayes	78.95	85.42	72.34	75.93	80.39	84.84	72.31
KNN	76.84	87.50	65.96	72.41	79.25	85.82	70.53







Curvas ROC (Cenário 80/20)



Curvas ROC (Cenario 70/30)





Heatmap de Metricas por Modelo (Cenario 80/20)



Heatmap de Metricas por Modelo (Cenario 70/30)





Faz sentido com a vida real?

Sim, se a interpretação for de **suporte à triagem**. O relatório não assume causalidade e não vende o modelo como substituto de imagem. O ponto central é que um painel pequeno, estável e de menor custo operacional costuma ser mais útil na prática do que um painel maior cuja melhora média é marginal.

Também há um cuidado importante: **variável preditiva não é automaticamente fator de risco epidemiológico**. Obesidade, metabolismo lipídico, diabetes e inflamação continuam clinicamente relevantes mesmo quando uma variável específica não aparece no topo do ranking em todos os splits.

Limitações

- Base pequena e de centro único.
- Possível instabilidade de ranking em amostra tabular curta.
- Algumas variáveis de bioimpedância são fortemente redundantes.
- O painel recomendado otimiza custo-benefício interno da base, mas não valida generalização externa.

Referências

- UCI ML Repository: <https://archive.ics.uci.edu/dataset/1150/gallstone-1>
- Referência clínica oficial: <https://www.niddk.nih.gov/health-information/digestive-diseases/gallstones/symptoms-causes>