

Analise de Dados: Gallstone Disease Prediction

Necessidade real de 10 features, custo-beneficio e plausibilidade clinica

31/03/2026

Contents

Introducao	1
Dataset e desenho analitico	1
Graficos exploratorios	2
Auditoria cientifica das features	5
Relevancia univariada (80/20)	5
Redundancia forte entre features (80/20)	6
Paineis candidatos e criterio de escolha	7
Conclusao objetiva	9
Por que o painel recomendado faz sentido	9
Justificativa feature por feature	9
Desempenho dos 9 modelos no painel de referencia interno	10
Cenario 80/20	10
Cenario 70/30	10
Painel recomendado (revalidado com 10-fold CV)	10
Faz sentido com a vida real?	16
Limitacoes	17
Referencias	17

Introducao

Este relatorio responde a uma pergunta metodologica e clinica: **o corte fixo em 10 features realmente e necessario nesta base?**

Toda a analise foi conduzida de forma **data-driven**, sem usar o artigo original como baseline de comparacao. O foco aqui e comparar paineis cumulativos e paineis podados por redundancia, sempre pesando desempenho, custo operacional de coleta e plausibilidade clinica.


Dataset e desenho analitico

- Base: Gallstone Disease Prediction (UCI).
- Amostra: 319 instancias e 38 preditoras.
- Variavel alvo: **Gallstone**.
- Paineis candidatos: **full_38**, **raw_top_k** e **pruned_top_k**.


- Painel de referencia interno: painel bruto com 10 variaveis derivado diretamente do ranking de importancia do treino.
- Triagem dos paineis: 5-fold CV com `tuneLength = 3`.
- Revalidacao final do painel de referencia e do painel recomendado: 10-fold CV com `tuneLength = 5`.


Painel de referencia interno: **raw_top_10**. Features 80/20: CRP, VitaminD, ECF_TBW, ECW, BM, TBFR, VMA, LM, HFA, VFA. Features 70/30: CRP, VitaminD, ECW, BM, TBFR, AST, ECF_TBW, LM, HDL, HFA.

Graficos exploratorios




Distribuicao por Genero e Status de Calculo Biliar





Matriz de Correlacao entre Variaveis Numericas



Auditoria cientifica das features

Relevancia univariada (80/20)

As comparacoes univariadas ajudam a separar sinal plausivel de ruido antes da selecao multivariada. Para variaveis numericas foi usado Wilcoxon; para categoricas, Fisher ou qui-quadrado, conforme a frequencia esperada.

Table 1: Top 15 features por relevancia univariada no treino 80/20

Feature	Grupo	Tipo	Teste	Estatistica	Pvalor	Efeito
CRP	Laboratorio	Numerica	Wilcoxon	3551.0	0.0000	-1.2800
VitaminD	Laboratorio	Numerica	Wilcoxon	11638.5	0.0000	8.5000
AST	Laboratorio	Numerica	Wilcoxon	10625.0	0.0000	3.0000
TBFR	Bioimpedancia	Numerica	Wilcoxon	6213.5	0.0008	-5.4100
LM	Bioimpedancia	Numerica	Wilcoxon	10140.0	0.0010	5.4000
HFA	HFA	Categorica	Fisher	NA	0.0011	0.1309
BM	Bioimpedancia	Numerica	Wilcoxon	10093.0	0.0013	0.3000
TFC	Bioimpedancia	Numerica	Wilcoxon	6468.5	0.0036	-4.5000

Feature	Grupo	Tipo	Teste	Estatistica	Pvalor	Efeito
ECF_TBW	Bioimpedancia	Numerica	Wilcoxon	9787.5	0.0069	0.0000
VFA	Bioimpedancia	Numerica	Wilcoxon	6630.5	0.0084	-2.0700
HDL	Laboratorio	Numerica	Wilcoxon	6631.5	0.0084	-3.0000
ECW	Bioimpedancia	Numerica	Wilcoxon	9728.5	0.0095	0.5000
Hyperlipidemia	Historia	Categorica	Fisher	NA	0.0140	0.0472
HGB	Laboratorio	Numerica	Wilcoxon	9509.0	0.0262	0.5000
BMI	Antropometria	Numerica	Wilcoxon	7057.5	0.0557	-1.4000

Redundancia forte entre features (80/20)

Em medicina aplicada, duas medidas quase equivalentes so devem coexistir se o ganho justificar o custo extra. Nesta base, varias features de composicao corporal andam juntas.




Table 2: Pares com $|r| \geq 0.85$ no treino 80/20

Feature1	Feature2	Correlacao
TBFR	LM	-0.994
BMI	Obesity	0.922
TBW	MM	0.913
BMI	TFC	0.908
TBW	ECW	0.894
ICW	MM	0.888
Weight	VFA	0.879

Feature1	Feature2	Correlacao
TFC	VFA	0.868
TBFR	TFC	0.866
LM	TFC	-0.863
TC	LDL	0.859
Obesity	TFC	0.858

Table 3: Clusters de redundancia no treino 80/20

Cluster	Tamanho	Feature
C01	1	Age
C02	1	Height
C03	7	BMI, LM, Obesity, TBFR, TFC, VFA, Weight
C04	4	ECW, ICW, MM, TBW
C05	1	ECF_TBW
C06	1	Protein
C07	1	VFR
C08	1	BM
C09	1	VMA
C10	1	Glucose
C11	2	LDL, TC
C12	1	HDL
C13	1	Triglyceride
C14	1	AST
C15	1	ALT
C16	1	ALP
C17	1	Creatinine
C18	1	GFR
C19	1	CRP
C20	1	HGB
C21	1	VitaminD

Paineis candidatos e criterio de escolha

- **full_38**: todas as variaveis.
- **raw_top_k**: ranking bruto de importancia do Random Forest com k de 3 a 15.
- **pruned_top_k**: ranking apos remover redundancia forte, com k de 3 a 15.
- **raw_top_10**: painel de referencia interno usado para testar se um corte fixo de 10 variaveis faz sentido nos dados.

Para viabilizar a comparacao extensa de paineis, a **triagem** usou 5-fold CV com **tuneLength** = 3. Depois da escolha do painel, o **painel de referencia interno** e o **painel recomendado** foram rerodados com 10-fold CV e **tuneLength** = 5 para a leitura final.

Regra de decisao usada:

- Elegivel se ficar ate 1 ponto percentual abaixo da melhor AUC media.
- Elegivel se ficar ate 2 pontos abaixo do melhor F1 medio.
- Elegivel se ficar ate 3 pontos abaixo da melhor sensibilidade media.
- Entre os elegiveis, vence o menor custo operacional.
- Empate: menor numero de features; novo empate: maior sensibilidade.





Table 4: Resumo global dos paineis candidatos

Painel_Base	Acuracia	Sensibilidade	F1	AUC	N_Features	Custo_Total	Elegivel	Recomendado
pruned_top_12	73.43	80.42	73.97	87.09	12	10.0	TRUE	FALSE
pruned_top_09	72.74	77.90	71.71	87.08	9	9.5	FALSE	FALSE
pruned_top_11	74.41	81.60	75.22	87.04	11	10.0	TRUE	TRUE
pruned_top_13	73.30	79.69	73.87	86.98	13	10.5	TRUE	FALSE
raw_top_12	72.56	74.94	71.69	86.88	12	9.5	FALSE	FALSE

Painel_Base	Acuracia	Sensibilidade	F1	AUC	N_Features	Custo_Total	Elegivel	Recomendado
raw_top_10	71.16	74.13	70.03	86.78	10	9.0	FALSE	FALSE
raw_top_11	72.39	74.77	71.20	86.74	11	9.5	FALSE	FALSE
pruned_top_10	71.74	76.10	70.61	86.61	10	9.5	FALSE	FALSE
pruned_top_14	71.63	74.42	69.42	86.60	14	10.5	FALSE	FALSE
raw_top_13	72.50	75.00	71.63	86.55	13	9.5	FALSE	FALSE
pruned_top_15	71.34	74.25	69.32	86.55	15	10.5	FALSE	FALSE
pruned_top_08	71.28	74.54	69.78	86.46	8	9.0	FALSE	FALSE
raw_top_14	73.56	77.09	73.07	86.44	14	10.0	FALSE	FALSE
raw_top_15	74.56	80.55	75.17	86.42	15	10.5	TRUE	FALSE
raw_top_07	72.10	80.38	73.16	85.51	7	5.0	FALSE	FALSE

Conclusao objetiva

O painel pruned_top_11 manteve 11 features e mostrou melhor equilibrio entre desempenho medio, estabilidade e custo-beneficio do que assumir um corte fixo e universal de 10 variaveis.

Painel recomendado: **pruned_top_11**. Features 80/20: CRP, VitaminD, ECF_TBW, ECW, BM, TBFR, VMA, HFA, AST, Protein, Hyperlipidemia. Features 70/30: CRP, VitaminD, ECW, TBFR, AST, ECF_TBW, HDL, HFA, Hyperlipidemia, Gender, Protein.

Custo medio do painel recomendado: **10.00**. Custo 80/20: **10**. Custo 70/30: **10**.

Por que o painel recomendado faz sentido

O painel recomendado foi interpretado como ferramenta de triagem, nao como substituto de ultrassonografia ou avaliacao clinica especializada.

Na pratica, o custo foi calculado por origem da informacao: Historia=1 + Laboratorio=2 + Bioimpedancia=3 + HFA=4 .

Isso permite comparar nao apenas desempenho estatistico, mas tambem o esforco humano e estrutural para coletar o painel: Historia + Laboratorio + Bioimpedancia + HFA .

Em linha com o NIDDK, fatores ligados a obesidade, metabolismo lipidico e diabetes fazem sentido biologico para colelitias, mesmo quando uma variavel nao lidera sozinha o ranking de importancia.

Justificativa feature por feature

- **CRP**: PCR capta inflamacao sistemica e foi uma das variaveis mais consistentes nos estudos.
- **VitaminD**: deficiencia de vitamina D foi destacada nos estudos e tem plausibilidade via estase biliar.
- **ECF_TBW**: a razao entre agua extracelular e agua corporal total resume o balanço hidrico sem usar duas medidas separadas.
- **ECW**: agua extracelular captura distribuicao hidrica e inflamada da composicao corporal.
- **BM**: massa ossea aparece como proxy de composicao corporal global e estado nutricional.
- **TBFR**: taxa de gordura corporal total expressa adiposidade, ligada a síndrome metabolica e litogenese.
- **VMA**: area muscular visceral pode representar fenotipo corporal e distribuicao de massa metabolica.
- **HFA**: acumulo de gordura hepatica conecta resistencia insulínica, esteatose e bile litogenica.
- **AST**: AST e um marcador hepatocelular inespecifico com plausibilidade em doenca hepatobiliar.
- **Protein**: conteudo proteico corporal atua como marcador indireto de composicao e estado nutricional.
- **Hyperlipidemia**: hiperlipidemia tem plausibilidade biologica direta por aumentar o ambiente litogenico.

Desempenho dos 9 modelos no painel de referencia interno

Cenario 80/20

Table 5: Painel de referencia interno - cenario 80/20 (revalidado com 10-fold CV)

Modelo	Acuracia	Sensibilidade	Especificidade	Precisao	F1	AUC	Acc_CV
Logistic Regression	84.13	93.75	74.19	78.95	85.71	90.62	77.31
Random Forest	85.71	87.50	83.87	84.85	86.15	92.04	77.35
AdaBoost	11.11	6.25	16.13	7.14	6.67	93.45	23.00
Gradient Boosting	87.30	93.75	80.65	83.33	88.24	92.94	77.02
MLP	85.71	96.88	74.19	79.49	87.32	91.83	78.52
SVM Radial	82.54	93.75	70.97	76.92	84.51	88.10	74.22
Decision Tree	79.37	90.62	67.74	74.36	81.69	86.04	70.28
Naive Bayes	60.32	25.00	96.77	88.89	39.02	93.45	64.83
KNN	74.60	87.50	61.29	70.00	77.78	90.47	71.54

Cenario 70/30

Table 6: Painel de referencia interno - cenario 70/30 (revalidado com 10-fold CV)

Modelo	Acuracia	Sensibilidade	Especificidade	Precisao	F1	AUC	Acc_CV
Logistic Regression	82.11	89.58	74.47	78.18	83.50	88.43	78.16
Random Forest	78.95	87.50	70.21	75.00	80.77	86.15	78.06
AdaBoost	27.37	10.42	44.68	16.13	12.66	80.59	20.53
Gradient Boosting	74.74	85.42	63.83	70.69	77.36	83.42	79.45
MLP	82.11	97.92	65.96	74.60	84.68	87.68	80.77
SVM Radial	83.16	85.42	80.85	82.00	83.67	89.27	74.51
Decision Tree	69.47	77.08	61.70	67.27	71.84	68.68	78.60
Naive Bayes	67.37	41.67	93.62	86.96	56.34	85.37	70.04
KNN	80.00	89.58	70.21	75.44	81.90	90.16	66.94


Painel recomendado (revalidado com 10-fold CV)


Table 7: Painel recomendado - cenario 80/20

Modelo	Acuracia	Sensibilidade	Especificidade	Precisao	F1	AUC	Acc_CV
Logistic Regression	92.06	96.88	87.10	88.57	92.54	90.62	79.31
Random Forest	88.89	93.75	83.87	85.71	89.55	94.76	78.51
AdaBoost	12.70	9.38	16.13	10.34	9.84	93.95	21.46
Gradient Boosting	84.13	84.38	83.87	84.38	84.38	90.73	79.69
MLP	85.71	96.88	74.19	79.49	87.32	90.42	78.54
SVM Radial	84.13	90.62	77.42	80.56	85.29	92.14	78.94
Decision Tree	79.37	90.62	67.74	74.36	81.69	86.04	68.72
Naive Bayes	84.13	84.38	83.87	84.38	84.38	93.25	75.72
KNN	80.95	90.62	70.97	76.32	82.86	92.04	70.77


Table 8: Painel recomendado - cenario 70/30

Modelo	Acuracia	Sensibilidade	Especificidade	Precisao	F1	AUC	Acc_CV
Logistic Regression	82.11	93.75	70.21	76.27	84.11	88.96	78.20
Random Forest	77.89	91.67	63.83	72.13	80.73	87.19	78.10
AdaBoost	24.21	10.42	38.30	14.71	12.20	82.62	20.99
Gradient Boosting	76.84	87.50	65.96	72.41	79.25	84.31	78.54
MLP	75.79	91.67	59.57	69.84	79.28	87.77	81.28
SVM Radial	81.05	89.58	72.34	76.79	82.69	86.79	75.47
Decision Tree	65.26	87.50	42.55	60.87	71.79	68.02	79.43
Naive Bayes	78.95	85.42	72.34	75.93	80.39	84.84	72.31
KNN	76.84	87.50	65.96	72.41	79.25	85.82	70.53







Curvas ROC (Cenário 80/20)



Curvas ROC (Cenário 70/30)





Heatmap de Metricas por Modelo (Cenario 80/20)



Heatmap de Metricas por Modelo (Cenario 70/30)





Faz sentido com a vida real?

Sim, se a interpretação for de **suporte a triagem**. O relatório não assume causalidade e não vende o modelo como substituto de imagem. O ponto central é que um painel pequeno, estável e de menor custo operacional costuma ser mais útil em prática do que um painel maior cuja melhoria média é marginal.

Tambem ha um cuidado importante: **feature preditiva nao e automaticamente fator de risco epidemiologico**. Obesidade, metabolismo lipidico, diabetes e inflamacao continuam clinicamente relevantes mesmo quando uma variavel especifica nao aparece no topo do ranking em todos os splits.

Limitacoes

- Base pequena e de centro unico.
- Possivel instabilidade de ranking em amostra tabular curta.
- Algumas variaveis de bioimpedancia sao fortemente redundantes.
- O painel recomendado otimiza custo-beneficio interno da base, nao valida generalizacao externa.

Referencias

- UCI ML Repository: <https://archive.ics.uci.edu/dataset/1150/gallstone-1>
- Referencia clinica oficial: <https://www.niddk.nih.gov/health-information/digestive-diseases/gallstones/symptoms-causes>