

Análise de Dados do Indian Liver Patient Dataset — ILPD

Projeto de Mineração de Dados

26/04/2026

Contents

Introdução	1
Descrição da base de dados	1
Metodologia	3
Análise exploratória	4
Valores ausentes	4
Estatísticas descritivas	4
Distribuição das variáveis numéricas	5
Correlação entre variáveis numéricas	6
Resultados dos modelos	6
Base completa	6
Apenas pacientes homens	8
Apenas pacientes mulheres	10
Comparação com o artigo	13
Melhor modelo	13
Discussão	14
Conclusão	14

Introdução

As doenças hepáticas representam um problema relevante de saúde pública, pois podem evoluir de forma silenciosa e gerar complicações graves quando não são identificadas precocemente. Nesse contexto, técnicas de ciência de dados, mineração de dados e aprendizado de máquina podem auxiliar a identificação de padrões clínicos relacionados à presença ou ausência de doença hepática.

O objetivo desta análise é construir uma abordagem mais completa e competitiva para o **Indian Liver Patient Dataset — ILPD**, comparando diferentes modelos de classificação, tratando o desbalanceamento das classes e avaliando os resultados por meio de métricas além da acurácia.

Descrição da base de dados

O ILPD contém registros de pacientes com variáveis demográficas e bioquímicas relacionadas à função hepática. A variável-alvo original, chamada **Selector**, assume valor 1 para pacientes com doença hepática e

2 para pacientes sem doença. Nesta análise, ela foi convertida para duas classes interpretáveis: **Doente** e **Saudavel**.


Linhas	Colunas
583	11

As variáveis utilizadas na análise são apresentadas abaixo.

Variavel	Classe R	Valores Ausentes	Valores Distintos
Age	integer	0	72
Gender	factor	0	2
Total_Bilirubin	numeric	0	113
Direct_Bilirubin	numeric	0	80
Alkaline_Phosphatase	integer	0	263
Alamine_Aminotransferase	integer	0	152
Aspartate_Aminotransferase	integer	0	177
Total_Proteins	numeric	0	58
Albumin	numeric	0	40
Albumin_and_Globulin_Ratio	numeric	4	69
Selector	factor	0	2


A distribuição das classes mostra que a base é desbalanceada, com maior presença de pacientes doentes.

Selector	Frequencia	Percentual
Doente	416	71.36
Saudavel	167	28.64



Também há predominância de pacientes do sexo masculino.

Gender	Frequencia	Percentual
Female	142	24.36
Male	441	75.64



Metodologia

A metodologia foi organizada para reduzir vazamento de dados e permitir comparação justa entre os modelos. As principais etapas foram:

1. carregamento do CSV localizado na pasta **dados/**;
2. renomeação das colunas para nomes claros;
3. conversão de **Gender** para fator;
4. conversão de **Selector** para as classes **Doente** e **Saudavel**;
5. verificação de valores ausentes, com atenção à variável **Albumin_and_Globulin_Ratio**;
6. separação estratificada em treino e teste;
7. validação cruzada estratificada com 10 folds no conjunto de treino;
8. tratamento do desbalanceamento com **upsampling dentro da validação cruzada**;
9. imputação por mediana, centralização, padronização e remoção de variáveis com variância zero dentro do fluxo de treino;
10. avaliação final apenas no conjunto de teste.

Foram testados os seguintes modelos:

- Regressão Logística;
- Random Forest;
- SVM com kernel radial;

- Naive Bayes;
- XGBoost.

As métricas principais foram **acurácia**, **sensitividade** e **especificidade**. Também foram calculadas **precisão**, **recall**, **F1-score** e **AUC**, quando disponíveis.

A análise foi repetida em três cenários:

- base completa;
- apenas pacientes homens;
- apenas pacientes mulheres.

Análise exploratória

Valores ausentes


A tabela abaixo apresenta a quantidade e o percentual de valores ausentes por variável. Quando existem valores faltantes em variáveis numéricas, o script usa imputação por mediana dentro do fluxo de treinamento, evitando uso indevido de informação do conjunto de teste.

Variavel	Ausentes	Percentual Ausente
Age	0	0.00
Gender	0	0.00
Total_Bilirubin	0	0.00
Direct_Bilirubin	0	0.00
Alkaline_Phosphatase	0	0.00
Alamine_Aminotransferase	0	0.00
Aspartate_Aminotransferase	0	0.00
Total_Proteins	0	0.00
Albumin	0	0.00
Albumin_and_Globulin_Ratio	4	0.69
Selector	0	0.00


Estatísticas descritivas

Variavel	Media	Mediana	Desvio Padrao	Minimo	Q1	Q3	Maximo	Ausentes
Age	44.7461	45.00	16.1898	4.0	33.0	58.0	90.0	0
Total_Bilirubin	3.2988	1.00	6.2095	0.4	0.8	2.6	75.0	0
Direct_Bilirubin	1.4861	0.30	2.8085	0.1	0.2	1.3	19.7	0
Alkaline_Phosphatase	290.5763	208.00	242.9380	63.0	175.5	298.0	2110.0	0
Alamine_Aminotransferase	80.7136	35.00	182.6204	10.0	23.0	60.5	2000.0	0
Aspartate_Aminotransferase	109.9108	42.00	288.9185	10.0	25.0	87.0	4929.0	0
Total_Proteins	6.4832	6.60	1.0855	2.7	5.8	7.2	9.6	0
Albumin	3.1419	3.10	0.7955	0.9	2.6	3.8	5.5	0
Albumin_and_Globulin_Ratio	0.9471	0.93	0.3196	0.3	0.7	1.1	2.8	4

Distribuição das variáveis numéricas



Correlação entre variáveis numéricas





Resultados dos modelos



A tabela comparativa final reúne todos os cenários e modelos avaliados. O melhor modelo não deve ser escolhido apenas pela acurácia, pois a base é desbalanceada. Por isso, a análise considera conjuntamente acurácia, sensibilidade, especificidade, F1-score e AUC.

Cenario	Modelo	Acuracia	Sensitividade	Especificidade	Precisao	Recall	F1	AUC
Completa	Random Forest	73.0%	83.1%	48.0%	79.8%	83.1%	81.4%	78.0%
Completa	Regressao Logistica	68.4%	62.1%	84.0%	90.6%	62.1%	73.7%	76.8%
Completa	SVM Radial	66.1%	66.1%	66.0%	82.8%	66.1%	73.5%	74.5%
Completa	Naive Bayes	64.9%	58.9%	80.0%	87.9%	58.9%	70.5%	72.3%
Homens	Random Forest	75.0%	82.5%	54.3%	83.3%	82.5%	82.9%	82.2%
Homens	SVM Radial	68.9%	63.9%	82.9%	91.2%	63.9%	75.1%	78.3%
Homens	Regressao Logistica	63.6%	56.7%	82.9%	90.2%	56.7%	69.6%	75.2%
Homens	Naive Bayes	48.5%	32.0%	94.3%	93.9%	32.0%	47.7%	73.0%
Mulheres	Random Forest	59.5%	63.0%	53.3%	70.8%	63.0%	66.7%	66.4%
Mulheres	SVM Radial	54.8%	51.8%	60.0%	70.0%	51.8%	59.6%	66.2%
Mulheres	Regressao Logistica	50.0%	37.0%	73.3%	71.4%	37.0%	48.8%	65.7%
Mulheres	Naive Bayes	50.0%	25.9%	93.3%	87.5%	25.9%	40.0%	38.0%

Base completa



Cenario	Modelo	Acuracia	Sensitividade	Especificidade	Precisao	Recall	F1	AUC
Completa	Random Forest	73.0%	83.1%	48.0%	79.8%	83.1%	81.4%	78.0%
Completa	Regressao Logistica	68.4%	62.1%	84.0%	90.6%	62.1%	73.7%	76.8%
Completa	SVM Radial	66.1%	66.1%	66.0%	82.8%	66.1%	73.5%	74.5%
Completa	Naive Bayes	64.9%	58.9%	80.0%	87.9%	58.9%	70.5%	72.3%







Apenas pacientes homens



Cenario	Modelo	Acuracia	Sensitividade	Especificidade	Precisao	Recall	F1	AUC
Homens	Random Forest	75.0%	82.5%	54.3%	83.3%	82.5%	82.9%	82.2%
Homens	SVM Radial	68.9%	63.9%	82.9%	91.2%	63.9%	75.1%	78.3%
Homens	Regressao Logistica	63.6%	56.7%	82.9%	90.2%	56.7%	69.6%	75.2%
Homens	Naive Bayes	48.5%	32.0%	94.3%	93.9%	32.0%	47.7%	73.0%







Apenas pacientes mulheres

Cenario	Modelo	Acuracia	Sensitividade	Especificidade	Precisao	Recall	F1	AUC
Mulheres	Random Forest	59.5%	63.0%	53.3%	70.8%	63.0%	66.7%	66.4%
Mulheres	SVM Radial	54.8%	51.8%	60.0%	70.0%	51.8%	59.6%	66.2%
Mulheres	Regressao Logistica	50.0%	37.0%	73.3%	71.4%	37.0%	48.8%	65.7%
Mulheres	Naive Bayes	50.0%	25.9%	93.3%	87.5%	25.9%	40.0%	38.0%






Comparação com o artigo

O artigo de referência testou modelos como ANN, Gaussian Naive Bayes, Generalized Linear Model, Regressão Logística, Random Forest, SVM e SVM com pesos de classe, com e sem seleção de atributos CFS. As acurácias aproximadas ficaram em torno de 71% a 76%, variando conforme o cenário.

A comparação abaixo usa os melhores resultados aproximados apresentados no artigo para cada cenário e os compara com os melhores modelos calculados por este projeto.

Cenário	Melhor Artigo Modelo	Melhor Artigo Acuracia	Melhor Projeto Modelo	Melhor Projeto Acuracia	Melhor Projeto Acuracia
Completa	Regressao Logistica sem CFS	75.3%	Regressao Logistica	68.4%	62.1%
Homens	Generalized Linear Model sem CFS	76.5%	Random Forest	75.0%	82.5%
Mulheres	SVM sem CFS	71.4%	Random Forest	59.5%	63.0%



Melhor modelo

A escolha do melhor modelo foi feita pelo **Score_Geral**, calculado a partir de acurácia, sensibilidade, especificidade, F1-score e AUC. Essa escolha é mais adequada do que usar apenas acurácia, pois o problema envolve classes desbalanceadas e exige atenção tanto aos pacientes doentes quanto aos saudáveis.

Cenário	Modelo	Acuracia	Sensitividade	Especificidade	Precisao	Recall	F1	AUC	Score Geral
Completa	Regressao Logistica	68.4%	62.1%	84.0%	90.6%	62.1%	73.7%	76.8%	73.0%
Homens	Random Forest	75.0%	82.5%	54.3%	83.3%	82.5%	82.9%	82.2%	75.4%
Mulheres	Random Forest	59.5%	63.0%	53.3%	70.8%	63.0%	66.7%	66.4%	61.8%

- No cenário **Completa**, o melhor modelo pelo critério composto foi **Regressao Logistica**, com acurácia de 68.4%, sensibilidade de 62.1%, especificidade de 84.0%, F1 de 73.7% e AUC de 76.8%.

- No cenário **Homens**, o melhor modelo pelo critério composto foi **Random Forest**, com acurácia de 75.0%, sensibilidade de 82.5%, especificidade de 54.3%, F1 de 82.9% e AUC de 82.2%.
- No cenário **Mulheres**, o melhor modelo pelo critério composto foi **Random Forest**, com acurácia de 59.5%, sensibilidade de 63.0%, especificidade de 53.3%, F1 de 66.7% e AUC de 66.4%.

Discussão

A análise realizada apresenta vantagens importantes em relação a uma avaliação baseada apenas em acurácia. Primeiro, a divisão treino/teste foi estratificada, preservando a proporção das classes. Segundo, a validação cruzada de 10 folds foi aplicada apenas no conjunto de treino. Terceiro, o balanceamento por upsampling foi feito dentro do processo de validação cruzada, o que reduz o risco de vazamento de dados.

Outra vantagem é a comparação entre diferentes famílias de modelos: modelos lineares, métodos probabilísticos, máquinas de vetores de suporte, florestas aleatórias e gradient boosting. Essa diversidade aumenta a chance de encontrar uma solução robusta para padrões lineares e não lineares.

Entre as limitações, deve-se destacar que o ILPD é uma base pequena e desbalanceada, especialmente no subconjunto feminino. Por isso, os resultados podem variar conforme a partição treino/teste, as versões dos pacotes e os hiperparâmetros avaliados. Além disso, mesmo modelos com boa acurácia podem ter desempenho insuficiente em sensibilidade ou especificidade, o que justifica a avaliação por múltiplas métricas.

Conclusão

Este projeto apresenta uma análise completa do ILPD, desde a exploração dos dados até a comparação de modelos supervisionados. A base foi analisada em três cenários, com tratamento de desbalanceamento, validação cruzada e avaliação por múltiplas métricas.

A análise mostra que a escolha do melhor modelo depende do cenário e não deve ser feita apenas pela acurácia. Métricas como sensibilidade, especificidade, F1-score e AUC fornecem uma visão mais completa do desempenho, especialmente porque a base é desbalanceada e envolve um problema de saúde.

Os arquivos produzidos pelo script permitem reproduzir os resultados, consultar as tabelas finais e visualizar os gráficos principais, tornando a entrega transparente, organizada e adequada para uma apresentação acadêmica.