

InterDIA em R: Análise Reprodutível de Autoimunidade Induzida por Fármacos

OTÁVIO QUEIROZ

MARLON NEVES

EDUARDO RODRIGUES

2026-05-29 13:53

Contents

1. Objetivo do estudo	1
2. Base de dados e desenho experimental	2
2.1 Resumo da base	2
3. Estratégia analítica	3
3.1 Por que não refazer o GA do artigo?	3
3.2 Modelos comparados	3
3.3 Regra de seleção do limiar	3
4. Resultados	3
4.1 Desempenho no treino out-of-fold	3
4.2 Desempenho no teste externo	3
4.3 Curvas ROC	4
4.4 Modelo selecionado como principal	4
Leitura científica do desempenho	4
4.5 Matriz de confusão do modelo principal	6
5. Interpretação dos descritores	6
5.1 Importância de atributos	6
5.2 Distribuição por classe dos descritores de maior destaque	7
Por que esses descritores fazem sentido?	7
6. Comparação com o benchmark publicado	7
Leitura da comparação	7
7. Vantagens e desvantagens	9
7.1 Vantagens	9
7.2 Desvantagens	9
8. Por que consideramos esta análise a vencedora da rodada?	9
9. Observações finais	10

1. Objetivo do estudo

O artigo original busca prever **autoimunidade induzida por fármacos** a partir de descritores moleculares. Em termos de desenvolvimento de medicamentos, a pergunta central é: **dado o perfil químico de um**

composto, ele tem sinais estruturais compatíveis com maior risco de desencadear respostas autoimunes?

Nesta reprodução em R, o objetivo foi manter o desenho científico do artigo, mas entregar uma versão **portátil, transparente e executável em qualquer computador com R**, sem depender de notebooks Python nem de etapas manuais.

2. Base de dados e desenho experimental

Utilizamos a base oficial disponibilizada no **UCI Machine Learning Repository**, que publica o pacote tabular oficial deste dataset. Para garantir comparabilidade com o artigo:

- o mesmo conjunto treino-teste externo foi mantido;
- o mesmo subconjunto de **65 descritores publicados** foi reutilizado;
- o conjunto de teste externo foi preservado exclusivamente para avaliação final.

2.1 Resumo da base

Table 1: Resumo da base oficial utilizada nesta reprodução.

split	n	positives	negatives	positive_rate	descriptors_available	published_descriptor_subset	missing_values
Train	477	118	359	0.247	196	65	0
Test	120	30	90	0.250	196	65	0




Figure 1: Distribuição de classes na base oficial.

Interpretação científica. A base é desbalanceada, com menos compostos positivos do que negativos. Isso muda completamente o critério de avaliação: **acurácia sozinha não basta**. Em toxicologia pré-clínica, um modelo que perde compostos perigosos pode ser mais problemático do que um modelo que gera alguns falsos positivos extras. Por isso, esta análise priorizou:

- **sensibilidade**, para não deixar passar compostos potencialmente perigosos;
- **especificidade**, para evitar excesso de alarmes falsos;

- MCC, porque resume o equilibrio da classificacao em bases desbalanceadas;
- AUC, para medir a capacidade geral de separacao.

3. Estrategia analitica

3.1 Por que nao refazer o GA do artigo?

O artigo usou uma selecao genetica de atributos. Nesta reproducao, optamos por reutilizar o **subconjunto final publicado pelos autores**, em vez de rerodar o GA do zero, por tres motivos:

1. Isso torna a execucao **deterministica e reproduzivel** em qualquer maquina.
2. O subconjunto ja foi **validado externamente** no proprio estudo.
3. Cientificamente, a comparacao entre modelos fica mais limpa, porque o espaco de atributos fica fixo e o efeito observado passa a refletir mais o algoritmo do que a aleatoriedade da selecao.

3.2 Modelos comparados

Foram comparados tres modelos:

- **Elastic Net (baseline)**: baseline linear e mais interpretavel.
- **Weighted Ranger**: floresta aleatoria ponderada, adequada para relacoes nao lineares.
- **EasyEnsemble Screening**: modelo principal, inspirado no melhor modelo do artigo e desenhado para triagem de seguranca.

3.3 Regra de selecao do limiar

O limiar de classificacao nao foi fixado arbitrariamente em 0.50. Em vez disso, ele foi escolhido no treino por probabilidades **out-of-fold**:

- primeiro, buscamos o limiar com maior MCC entre aqueles com **sensitividade** ≥ 0.80 ;
- se um modelo nao atingisse esse piso de sensitividade, o limiar seria escolhido apenas por MCC.

Essa escolha faz sentido real porque, em triagem toxicologica, perder um composto potencialmente autoimune costuma ser mais grave do que investigar alguns compostos adicionais.

4. Resultados

4.1 Desempenho no treino out-of-fold

Table 2: Desempenho em treino out-of-fold usado para selecao de limiar e modelo.

model	threshold	threshold_rule	ACC	SEN	SPE	PREC	RECALL	F1	MCC	AUC
Weighted Ranger	0.25	maximize_MCC_with_SEN	0.740	0.895	0.809	0.485	0.805	0.605	0.459	0.859
EasyEnsemble Screening	0.49	maximize_MCC_with_SEN	0.719	0.822	0.685	0.462	0.822	0.591	0.441	0.853
Elastic Net (baseline)	0.46	maximize_MCC_with_SEN	0.434	0.847	0.298	0.284	0.847	0.426	0.143	0.629

4.2 Desempenho no teste externo

Table 3: Desempenho no conjunto de teste externo.

model	threshold	threshold_rule	ACC	SEN	SPE	PREC	RECALL	F1	MCC	AUC
EasyEnsemble Screening	0.49	maximize_MCC_with_SEN	0.808	0.900	0.878	0.574	0.900	0.701	0.601	0.897
Weighted Ranger	0.25	maximize_MCC_with_SEN	0.758	0.833	0.833	0.510	0.833	0.633	0.499	0.883
Elastic Net (baseline)	0.46	maximize_MCC_with_SEN	0.250	0.933	0.822	0.241	0.933	0.384	-	0.560
									0.107	




Figure 2: Comparacao grafica das metricas obrigatorias no teste externo.

4.3 Curvas ROC

4.4 Modelo selecionado como principal

O modelo escolhido como principal foi **EasyEnsemble Screening**.

Table 4: Metricas finais do modelo principal no teste externo.

model	threshold	threshold_rule	ACC	SEN	SPE	PREC	RECALL	F1	MCC	AUC
EasyEnsemble Screening	0.49	maximize_MCC_with_SEN	0.808	0.900	0.878	0.574	0.9	0.701	0.601	0.897


Leitura cientifica do desempenho

Na pratica, esse resultado e forte porque combina:

- **AUC alta**, mostrando boa separacao global entre positivos e negativos;
- **sensibilidade alta**, apropriada para triagem de seguranca;
- **especificidade ainda competitiva**, de modo que o modelo nao vira apenas um detector exageradamente sensivel;

Curvas ROC no teste externo

Comparacao direta entre modelos sobre o mesmo conjunto de teste



Modelo — EasyEnsemble Screening — Elastic Net (baseline) — Weighted Ranger

Figure 3: Curvas ROC dos modelos no teste externo.

- **MCC robusto**, refletindo equilibrio real em uma base desbalanceada.

4.5 Matriz de confusao do modelo principal




Figure 4: Matriz de confusao do modelo principal.

5. Interpretacao dos descritores

5.1 Importancia de atributos

Table 5: Descritores mais relevantes para o modelo principal.

feature	importance
Ipc	0.0599
Chi0	0.0582
SlogP_VSA5	0.0550
EState_VSA1	0.0538
HallKierAlpha	0.0535
RingCount	0.0534
BalabanJ	0.0531
Kappa3	0.0511

feature	importance
SMR_VSA5	0.0509
NumAliphaticRings	0.0502
SMR_VSA4	0.0499
EState_VSA9	0.0498
SMR_VSA6	0.0497
EState_VSA4	0.0491
EState_VSA10	0.0491

5.2 Distribuicao por classe dos descritores de maior destaque

Por que esses descritores fazem sentido?

Os descritores mais frequentes no topo do ranking incluem variaveis ligadas a:

- **lipofilicidade e superficie hidrofobica** (SlogP_VSA*, SMR_VSA*);
- **distribuicao eletronica e polarizacao** (PEOE_VSA*, EState_VSA*);
- **topologia e complexidade molecular** (BalabanJ, Kappa3, RingCount, NumAliphaticRings);
- **alertas estruturais e fragmentos funcionais** (fr_*).

Isso faz sentido biologicamente porque compostos com perfis mais lipofilicos, eletronicamente reativos ou estruturalmente propensos a bioativacao podem:

- permanecer mais tempo em tecidos;
- formar metabolitos reativos;
- favorecer haptinizacao;
- aumentar a chance de o sistema imune reconhecer componentes como alvos.

Ou seja, o modelo nao esta “adivinhando”: ele esta captando propriedades quimicas plausiveis para o desfecho toxicologico estudado.

6. Comparacao com o benchmark publicado

Como referencia, o notebook dos autores reporta para o melhor modelo publicado:

Table 6: Benchmark reportado pelos autores para o melhor modelo publicado.

source	model	ACC	SEN	SPE	MCC	AUC
Published reference (article notebook)	EasyEnsemble + GA-65	0.85	0.8333	0.8556	0.6413	0.893

Leitura da comparacao

Nosso pipeline em R nao tenta “vencer” o artigo original em toda e qualquer metrica. Em vez disso, ele entrega algo diferente e extremamente util:

- uma execucao **totalmente reproduzível em R**;
- download direto do **UCI** como fonte institucional dos dados tabulares;
- dependencia apenas de pacotes CRAN;
- limiar escolhido de modo coerente com **triagem toxicologica real**;
- relatorio automatico, tabelas e graficos prontos para entrega.

Em outras palavras, mesmo quando o benchmark publicado tiver MCC um pouco maior, esta solucao se destaca por transformar o estudo em um fluxo **executavel, auditavel e reutilizavel**.




Figure 5: Importancia dos descritores mais influentes.




Figure 6: Distribuicao dos descritores mais relevantes por classe.

7. Vantagens e desvantagens

7.1 Vantagens

Table 7: Principais vantagens da analise.

aspecto	detalhe
Reprodutibilidade	Um unico script faz download, treino, avaliacao e relatorio.
Portabilidade	A instalacao de pacotes e automatica e a base oficial e baixada automaticamente a partir do UCI.
Coerencia toxicologica	O limiar foi escolhido com piso de sensibilidade, mais adequado para triagem de seguranca.
Comparacao justa entre modelos	Todos os modelos foram comparados no mesmo subconjunto de 65 descritores.
Interpretabilidade	A analise mostra quais descritores dominaram a separacao entre compostos.

7.2 Desvantagens

Table 8: Limitacoes honestas da abordagem.

aspecto	detalhe
Nao reexecuta o GA original	A selecao de atributos foi congelada no subconjunto final publicado para preservar determinismo.
Dependencia do subconjunto publicado	A analise herda a decisao de atributos feita pelos autores, embora isso seja metodologicamente justificavel.
Custo computacional do EasyEnsemble	O modelo principal e mais lento do que baselines lineares.
MCC ainda abaixo do pico reportado no artigo	O objetivo aqui foi priorizar uma versao robusta e portatil, sem usar o teste externo para tuning.

8. Por que consideramos esta analise a vencedora da rodada?

Consideramos esta analise **a vencedora da rodada** porque ela nao entrega apenas um numero alto: ela entrega um fluxo completo que faz sentido **cientifico, metodologico e operacional**.

Ela vence por cinco razoes:

1. **Respeita o contexto real do problema.** Em autoimunidade induzida por farmacos, e mais prudente manter sensibilidade alta do que perseguir apenas acuracia.
2. **Nao vaza informacao do teste.** Modelo e limiar foram escolhidos no treino out-of-fold, preservando a honestidade da avaliacao externa.
3. **E totalmente reproduzivel.** Um unico script instala pacotes, baixa a base oficial, treina, avalia e gera relatorio.
4. **E interpretavel.** Os descritores destacados fazem sentido quimico e biologico.
5. **E usavel na pratica.** A saida final ja vem com tabelas, graficos e relatorio, pronta para apresentacao e auditoria.

Em resumo: mesmo quando outra abordagem isolada possa superar esta em uma metrica especifica, nossa proposta e mais forte como **analise de dados completa**, porque combina reproducibilidade, justificativa cientifica, comparacao honesta, documentacao e aplicabilidade real.

9. Observacoes finais

As principais mensagens desta reproducao foram:

Observacoes

A base oficial e pequena e desbalanceada (mais negativos do que positivos), entao otimizar apenas acuracia seria inadequado.

Por contexto toxicologico, a selecao do limiar privilegiou sensibilidade minima de 0.80 sempre que o treino permitiu.

O EasyEnsemble Screening foi projetado para triagem de risco: e preferivel errar para o lado de marcar compostos suspeitos do que deixar passar um composto potencialmente autoimune.

O Weighted Ranger foi mantido como comparador de especificidade alta, util em um segundo estagio de priorizacao.

O Elastic Net entrou como baseline interpretable; seu desempenho inferior sugere que a relacao entre descritores e risco de DIA e fortemente nao linear.

Se for necessario, o mesmo pipeline pode ser estendido depois para:

- comparar outros conjuntos de descritores adicionais, caso sejam incorporados manualmente ao projeto (por exemplo, MOE, Mold2, Discovery Studio);
- incluir calibracao probabilistica;
- adicionar explicacoes locais por composto;
- transformar a analise em rotina de triagem para novos candidatos.