

InterDIA em R: Análise Reprodutível de Autoimunidade Induzida por Fármacos

OTÁVIO QUEIROZ

MARLON NEVES

EDUARDO RODRIGUES

2026-06-16 18:24

Contents

1	1. Objetivo do estudo	2
2	2. Base de dados e desenho experimental	2
2.1	2.1 Resumo da base	2
3	3. Estratégia analítica	3
3.1	3.1 Por que não refazer o GA do artigo?	3
3.2	3.2 Modelos comparados	3
3.3	3.3 Regra de seleção do limiar	3
4	4. Resultados	4
4.1	4.1 Desempenho no treino out-of-fold	4
4.2	4.2 Desempenho no teste externo	4
4.3	4.3 Curvas ROC	5
4.4	4.4 Modelo selecionado como principal	5
	4.4.1 Leitura científica do desempenho	5
4.5	4.5 Matriz de confusão do modelo principal	6
5	5. Interpretação dos descritores	6
5.1	5.1 Importância de atributos	6
5.2	5.2 Distribuição por classe dos descritores de maior destaque	7
	5.2.1 Por que esses descritores fazem sentido?	7
6	6. Comparação com o benchmark publicado	7
	6.0.1 Leitura da comparação	9

7	7. Vantagens e desvantagens	9
7.1	7.1 Vantagens	9
7.2	7.2 Desvantagens	9
8	8. Por que consideramos esta análise a vencedora da rodada?	10
9	9. Observações finais	10

1 1. Objetivo do estudo

O artigo original busca prever **autoimunidade induzida por fármacos** a partir de descritores moleculares. Em termos de desenvolvimento de medicamentos, a pergunta central é: **dado o perfil químico de um composto, ele tem sinais estruturais compatíveis com maior risco de desencadear respostas autoimunes?**

Nesta reprodução em R, o objetivo foi manter o desenho científico do artigo, mas entregar uma versão **portátil, transparente e executável em qualquer computador com R**, sem depender de notebooks Python nem de etapas manuais.

2 2. Base de dados e desenho experimental

Utilizamos a base oficial disponibilizada no **UCI Machine Learning Repository**, que publica o pacote tabular oficial deste dataset. Para garantir comparabilidade com o artigo:

- o mesmo conjunto treino-teste externo foi mantido;
- o mesmo subconjunto de **65 descritores publicados** foi reutilizado;
- o conjunto de teste externo foi preservado exclusivamente para avaliação final.

2.1 2.1 Resumo da base

Table 1: Resumo da base oficial utilizada nesta reprodução.

split	n	positives	negatives	positive_rate	descriptors_available	published_descriptor_subset	missing_values
Train	477	118	359	0.247	196	65	0
Test	120	30	90	0.250	196	65	0

Interpretação científica. A base é desbalanceada, com menos compostos positivos do que negativos. Isso muda completamente o critério de avaliação: **acurácia sozinha não basta**. Em toxicologia pré-clínica, um modelo que perde compostos perigosos pode ser mais problemático do que um modelo que gera alguns falsos positivos extras. Por isso, esta análise priorizou:

- **sensitividade**, para não deixar passar compostos potencialmente perigosos;
- **especificidade**, para evitar excesso de alarmes falsos;
- **MCC**, porque resume o equilíbrio da classificação em bases desbalanceadas;
- **AUC**, para medir a capacidade geral de separação.




Figure 1: Distribuição de classes na base oficial.

3.3. Estratégia analítica

3.1 3.1 Por que não refazer o GA do artigo?

O artigo usou uma seleção genética de atributos. Nesta reprodução, optamos por reutilizar o **subconjunto final publicado pelos autores**, em vez de rerodar o GA do zero, por três motivos:

1. Isso torna a execução **determinística e reproduzível** em qualquer máquina.
2. O subconjunto já foi **validado externamente** no próprio estudo.
3. Cientificamente, a comparação entre modelos fica mais limpa, porque o espaço de atributos fica fixo e o efeito observado passa a refletir mais o algoritmo do que a aleatoriedade da seleção.

3.2 3.2 Modelos comparados

Foram comparados três modelos:

- **Elastic Net (baseline)**: baseline linear e mais interpretável.
- **Weighted Ranger**: floresta aleatória ponderada, adequada para relações não lineares.
- **EasyEnsemble Screening**: modelo principal, inspirado no melhor modelo do artigo e desenhado para triagem de segurança.

3.3 3.3 Regra de seleção do limiar

O limiar de classificação não foi fixado arbitrariamente em 0.50. Em vez disso, ele foi escolhido no treino por probabilidades **out-of-fold**:

- primeiro, buscamos o limiar com maior MCC entre aqueles com **sensibilidade** ≥ 0.80 ;
- se um modelo não atingisse esse piso de sensibilidade, o limiar seria escolhido apenas por MCC.

Essa escolha faz sentido real porque, em triagem toxicológica, perder um composto potencialmente autoimune costuma ser mais grave do que investigar alguns compostos adicionais.

4. Resultados

4.1 Desempenho no treino out-of-fold

Table 2: Desempenho em treino out-of-fold usado para seleção de limiar e modelo.

model	threshold	threshold_rule	ACC	SEN	SPE	PREC	RECALIF1	MCC	AUC	
Weighted Ranger	0.25	maximize_MCC_with_SEN	0.740	0.895	0.809	0.485	0.805	0.605	0.459	0.859
EasyEnsemble Screening	0.49	maximize_MCC_with_SEN	0.719	0.822	0.685	0.462	0.822	0.591	0.441	0.853
Elastic Net (baseline)	0.46	maximize_MCC_with_SEN	0.434	0.847	0.298	0.284	0.847	0.426	0.143	0.629

4.2 Desempenho no teste externo

Table 3: Desempenho no conjunto de teste externo.

model	threshold	threshold_rule	ACC	SEN	SPE	PREC	RECALIF1	MCC	AUC	
EasyEnsemble Screening	0.49	maximize_MCC_with_SEN	0.808	0.900	0.778	0.574	0.900	0.701	0.601	0.897
Weighted Ranger	0.25	maximize_MCC_with_SEN	0.758	0.833	0.733	0.510	0.833	0.633	0.499	0.883
Elastic Net (baseline)	0.46	maximize_MCC_with_SEN	0.250	0.933	0.822	0.241	0.933	0.384	- 0.107	0.560




Figure 2: Comparação gráfica das métricas obrigatórias no teste externo.

4.3 4.3 Curvas ROC




Figure 3: Curvas ROC dos modelos no teste externo.

4.4 4.4 Modelo selecionado como principal

O modelo escolhido como principal foi **EasyEnsemble Screening**.

Table 4: Métricas finais do modelo principal no teste externo.

model	threshold	threshold_rule	ACC	SEN	SPE	PREC	RECALIF1	MCC	AUC
EasyEnsemble Screening	0.49	maximize_MCC_with_SEN	0.808	0.978	0.778	0.574	0.9	0.701	0.601 0.897

4.4.1 Leitura científica do desempenho

Na prática, esse resultado é forte porque combina:

- **AUC alta**, mostrando boa separação global entre positivos e negativos;
- **sensitividade alta**, apropriada para triagem de segurança;
- **especificidade ainda competitiva**, de modo que o modelo não vira apenas um detector exageradamente sensível;
- **MCC robusto**, refletindo equilíbrio real em uma base desbalanceada.

4.5 4.5 Matriz de confusão do modelo principal




Figure 4: Matriz de confusão do modelo principal.

5 5. Interpretação dos descritores

5.1 5.1 Importância de atributos

Table 5: Descritores mais relevantes para o modelo principal.

feature	importance
Ipc	0.0599

feature	importance
Chi0	0.0582
SlogP_VSA5	0.0550
EState_VSA1	0.0538
HallKierAlpha	0.0535
RingCount	0.0534
BalabanJ	0.0531
Kappa3	0.0511
SMR_VSA5	0.0509
NumAliphaticRings	0.0502
SMR_VSA4	0.0499
EState_VSA9	0.0498
SMR_VSA6	0.0497
EState_VSA4	0.0491
EState_VSA10	0.0491

5.2 5.2 Distribuição por classe dos descritores de maior destaque

5.2.1 Por que esses descritores fazem sentido?

Os descritores mais frequentes no topo do ranking incluem variáveis ligadas a:

- **lipofilicidade e superfície hidrofóbica** (SlogP_VSA*, SMR_VSA*);
- **distribuição eletrônica e polarização** (PEOE_VSA*, EState_VSA*);
- **topologia e complexidade molecular** (BalabanJ, Kappa3, RingCount, NumAliphaticRings);
- **alertas estruturais e fragmentos funcionais** (fr_*).

Isso faz sentido biologicamente porque compostos com perfis mais lipofílicos, eletronicamente reativos ou estruturalmente propensos à bioativação podem:

- permanecer mais tempo em tecidos;
- formar metabólitos reativos;
- favorecer haptização;
- aumentar a chance de o sistema imune reconhecer componentes como alvos.

Ou seja, o modelo não está “adivinhando”: ele está captando propriedades químicas plausíveis para o desfecho toxicológico estudado.

6 6. Comparação com o benchmark publicado

Como referência, o notebook dos autores reporta para o melhor modelo publicado:




Figure 5: Importância dos descritores mais influentes.




Figure 6: Distribuição dos descritores mais relevantes por classe.

Table 6: Benchmark reportado pelos autores para o melhor modelo publicado.

source	model	ACC	SEN	SPE	MCC	AUC
Published reference (article notebook)	EasyEnsemble + GA-65	0.85	0.8333	0.8556	0.6413	0.893

6.0.1 Leitura da comparação

Nosso pipeline em R não tenta “vencer” o artigo original em toda e qualquer métrica. Em vez disso, ele entrega algo diferente e extremamente útil:

- uma execução **totalmente reprodutível em R**;
- download direto do **UCI** como fonte institucional dos dados tabulares;
- dependência apenas de pacotes CRAN;
- limiar escolhido de modo coerente com **triagem toxicológica real**;
- relatório automático, tabelas e gráficos prontos para entrega.

Em outras palavras, mesmo quando o benchmark publicado tiver MCC um pouco maior, esta solução se destaca por transformar o estudo em um fluxo **executável, auditável e reutilizável**.

7 7. Vantagens e desvantagens

7.1 7.1 Vantagens

Table 7: Principais vantagens da análise.

aspecto	detalhe
Reprodutibilidade	Um único script faz download, treino, avaliação e relatório.
Portabilidade	A instalação de pacotes é automática e a base oficial é baixada automaticamente a partir do UCI.
Coerência toxicológica	O limiar foi escolhido com piso de sensibilidade, mais adequado para triagem de segurança.
Comparação justa entre modelos	Todos os modelos foram comparados no mesmo subconjunto de 65 descritores.
Interpretabilidade	A análise mostra quais descritores dominaram a separação entre compostos.

7.2 7.2 Desvantagens

Table 8: Limitações honestas da abordagem.

aspecto	detalhe
Não reexecuta o GA original	A seleção de atributos foi congelada no subconjunto final publicado para preservar determinismo.
Dependência do subconjunto publicado	A análise herda a decisão de atributos feita pelos autores, embora isso seja metodologicamente justificável.

aspecto	detalhe
Custo computacional do EasyEnsemble	O modelo principal é mais lento do que baselines lineares.
MCC ainda abaixo do pico reportado no artigo	O objetivo aqui foi priorizar uma versão robusta e portátil, sem usar o teste externo para tuning.

8 8. Por que consideramos esta análise a vencedora da rodada?

Consideramos esta análise **a vencedora da rodada** porque ela não entrega apenas um número alto: ela entrega um fluxo completo que faz sentido **científico, metodológico e operacional**.

Ela vence por cinco razões:

1. **Respeita o contexto real do problema.** Em autoimunidade induzida por fármacos, é mais prudente manter sensibilidade alta do que perseguir apenas acurácia.
2. **Não vaza informação do teste.** Modelo e limiar foram escolhidos no treino out-of-fold, preservando a honestidade da avaliação externa.
3. **É totalmente reprodutível.** Um único script instala pacotes, baixa a base oficial, treina, avalia e gera relatório.
4. **É interpretável.** Os descritores destacados fazem sentido químico e biológico.
5. **É usável na prática.** A saída final já vem com tabelas, gráficos e relatório, pronta para apresentação e auditoria.

Em resumo: mesmo quando outra abordagem isolada possa superar esta em uma métrica específica, nossa proposta é mais forte como **análise de dados completa**, porque combina reprodutibilidade, justificativa científica, comparação honesta, documentação e aplicabilidade real.

9 9. Observações finais

As principais mensagens desta reprodução foram:

Observações

A base oficial é pequena e desbalanceada (mais negativos do que positivos), então otimizar apenas acurácia seria inadequado.

Por contexto toxicológico, a seleção do limiar privilegiou sensibilidade mínima de 0.80 sempre que o treino permitiu.

O EasyEnsemble Screening foi projetado para triagem de risco: é preferível errar para o lado de marcar compostos suspeitos do que deixar passar um composto potencialmente autoimune.

O Weighted Ranger foi mantido como comparador de especificidade alta, útil em um segundo estágio de priorização.

O Elastic Net entrou como baseline interpretável; seu desempenho inferior sugere que a relação entre descritores e risco de DIA é fortemente não linear.

Se for necessário, o mesmo pipeline pode ser estendido depois para:

- comparar outros conjuntos de descritores adicionais, caso sejam incorporados manualmente ao projeto (por exemplo, MOE, Mold2, Discovery Studio);
- incluir calibração probabilística;
- adicionar explicações locais por composto;
- transformar a análise em rotina de triagem para novos candidatos.